


Выбросы

Аномальные наблюдения в данных или **выбросы** (*Outliers, Extreme values*) – это такие значения, которые значительно отличаются от большинства других значений выборки.



Выброс – это часто реально существующий объект, но обладающий аномальными свойствами, он сильно отличается от других объектов выборки.

При выявлении подобных «выбросов» возникают серьезные вопросы: являются ли отклоняющиеся данные действительно ошибками (например, регистрации) или это реальные значения и как получить адекватные оценки для параметров изучаемой совокупности.

Надо ли избавляться от выбросов?

1. Если данные будут использоваться при решении задачи прогнозирования, то удаление выбросов, как правило, повышает точность предсказания (правило «мусор на входе – мусор на выходе»)
2. Удаление выбросов позволяет получить нормальные (типичные, эталонные) объекты.
3. Многие числовые характеристики выборки (например, среднее значение или среднеквадратичное отклонение) очень чувствительны к наличию выбросов.

Проблемы устранения выбросов

Идеальных методов обнаружения выбросов не бывает, потому что:

1. Не существует формального (строгого математического) определения выброса. В разных ситуациях граница между нормой и аномалией может быть расплывчатой.
2. Алгоритм, беспощадный к выбросам, будет удалять и часть «нормальных» объектов.
3. Алгоритм, лояльный к «выбросам», будет пропускать часть выбросов.

Построить идеальный детектор выбросов – всё равно, что предложить медицинский анализ без ложноположительных и ложноотрицательных результатов.



Методы обнаружения выбросов

К сожалению, нет универсального метода или алгоритма поиска экстремальных значений. Как минимум потому, что существуют много критериев и подходов для идентификации выбросов.

Решение о том, что правильнее применить, остается за аналитиком.

1. Поиск аномальных объектов с помощью **здравого смысла**.

Пример: человек с ростом более 200 см – такие люди могут в реальности существовать, но их очень мало, лучше их объявить выбросами.

2. Методы, основанные на анализе одного признака (каждый признак берётся отдельно и ищутся объекты с аномальными значениями этого признака).
3. Методы, основанные на одновременном анализе нескольких признаков (многомерные выборки).

Методы обнаружения выбросов

Самым простым инструментом выявления выбросов является визуализация. Она позволяет сразу разглядеть отклонения, незаметные на больших наборах данных.

Также используются параметрические и непараметрические методы обнаружения выбросов.

Методы, анализирующие признаки по отдельности


1. «Правило N сигм»

$M(X) = a$ — математическое ожидание

(среднее значение) X

σ (сигма) — стандартное отклонение

(отклонение от среднего) X



Чем ближе значение X к среднему, тем большей вероятностью оно встречается.

Правило

3-х сигм:

99,7%

все значения нормально распределенной случайной величины отклоняются от математического ожидания не более чем на 3 стандартных отклонения

Алгоритм «Правила N сигм»

1. Пусть x – подозрительное значение.
2. Исключим x из выборки и по оставшимся элементам вычислим среднее и отклонение.
3. Если x выходит за пределы N сигма, можно объявить его выбросом.

Если распределение выборки **симметричное**, используют $N = 3$.

$$(\bar{X} - 3\sigma; \bar{X} + 3\sigma)$$

Если **несимметричное**: $N = 5$.

$$(\bar{X} - 5\sigma; \bar{X} + 5\sigma)$$

Симметричность выборки позволяет определить **коэффициент асимметрии (в прошлой лекции)**.

Пример «Правила N сигм»

Пример. Имеются данные о заработной плате сотрудников компании N (тыс. руб.):

22, 32, 34, 41, 36, 170, 36.

Решение. Вычислим среднее по всей выборке $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{7} (22 + 32 + 34 + 41 + 36 + 170 + 36) = 53$ тыс.руб.

Опять проблема состоит в том, что у шести человек из 7 заработная плата ниже, чем средняя и только у одного человека – выше.

Проверим, является ли значение 170 тыс.руб выбросом в данной выборке с помощью «Правила N сигм».

Пример «Правила N сигм»

Удалим из выборки наблюдение, подозрительное на выбросы – это 170 и по оставшейся выборке из 6 наблюдений определим

Среднее $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{6} (22 + 32 + 34 + 41 + 36 + 36) = 33,5 \text{ тыс. руб.}$

Дисперсию $S_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} = \frac{1}{6} ((22 - 33,5)^2 + (32 - 33,5)^2 + (34 - 33,5)^2 + (41 - 33,5)^2 + (36 - 33,5)^2 + (36 - 33,5)^2) = 33,92 (\text{тыс. руб.})^2$

Среднее квадратичное отклонение $S_X = \sqrt{S_X^2} = \sqrt{33,92} = 5,82 \text{ тыс. руб.}$

Коэффициент асимметрии найдем по формуле $As = \frac{\mu_3}{S_X^3}$, где

$$\mu_3 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3.$$

Пример «Правила N сигм»

В нашем примере $\mu_3 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3 = \frac{1}{6} ((22 - 33,5)^3 + (32 - 33,5)^3 + (34 - 33,5)^3 + (41 - 33,5)^3 + (36 - 33,5)^3 + (36 - 33,5)^3) = -178,5$.

А сам коэффициент асимметрии будет отрицательным

$As = \frac{\mu_3}{S_X^3} = \frac{-178,5}{(5,82)^3} = -0,9$, что говорит о левосторонней асимметрии (*несимметричное распределение*).

Значит, используем $N = 5$: $(\bar{X} - 5 * S_X; \bar{X} + 5 * S_X) = (33,5 - 5 * 5,82; 33,5 + 5 * 5,82) = (4,4; 62,5)$, т.е. все значения, которые попадают за границы этого интервала, будут выбросами.

В нашем случае значение **170 – выброс**, т.к. не попадает в интервал от 4,4 до 62,5.

2. Критерий Шовене (Chauvenet)

Значение X_i является выбросом, если выполнено неравенство

$$\operatorname{erfc}\left(\frac{|X_i - \bar{X}|}{S_X}\right) < \frac{1}{2n}$$

где $\operatorname{erfc}(x) = \frac{2}{\sqrt{\pi}} \int_x^{+\infty} e^{-t} dt$ – дополнение к функции ошибок.

В Python функция `erfc()` есть в модуле `math`.

Удаляем выброс, затем на оставшихся данных повторяем процедуру – до тех пор, пока крайнее значение не будет оказываться выбросом, т.е. выбросов не останется.

Константу 2 (в формуле) можно заменить на любую другую. Это сделает критерий более беспощадным (либо более лояльным) к выбросам. Чем больше число, тем лояльнее критерий (меньше значений будет определяться как выброс).

Пример Критерия Шовене (Chauvenet)

Пример. Имеются данные о заработной плате сотрудников компании N (тыс. руб.):

22, 32, 34, 41, 36, 170, 36.

Решение. Вычислим среднее по всей выборке $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{7} (22 + 32 + 34 + 41 + 36 + 170 + 36) = 53$ тыс.руб.

Найдем дисперсию и среднеквадратичное отклонение по всей выборке из 7 наблюдений.

$$\begin{aligned} S_{\bar{X}}^2 &= \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n} \\ &= \frac{1}{7} ((22 - 53)^2 + (32 - 53)^2 + (34 - 53)^2 + (41 - 53)^2 \\ &\quad + (36 - 53)^2 + (170 - 53)^2 + (36 - 53)^2) = 2310,57 (\text{тыс. руб})^2 \end{aligned}$$

Среднее квадратичное отклонение $S_X = \sqrt{S_X^2} = \sqrt{2310,57} = 48,07$ тыс.руб.

Приме Критерия Шовене (Chauvenet)

Считаем статистику

$$erfc\left(\frac{|X_i - \bar{X}|}{S_X}\right) = erfc\left(\frac{170 - 53}{48,07}\right) = 0,01$$

Это значение меньше, чем $\frac{1}{2n} = \frac{1}{2*7} = 0,07$, а это значит, что **170 является выбросом.**

Использование непараметрических методов

Есть затруднение:


Значения среднего и отклонения сильно чувствительны к наличию выбросов.

Таким образом, возникает замкнутый круг: мы ищем выбросы спомощью среднего и отклонения, чьи значения как раз и обусловлены наличием выбросов.

Возникает идея искать выбросы без использования величин, которые сильно зависят от выбросов.

Квантиль уровня — это значение X , меньше которого окажется $p\%$ значений X в выборке (или генеральной совокупности) (например, для речь идет о 75% совокупности).

Критерий, основанный на квартилях




выборки


- **1-ая квартиль** $Q_1 = X_{0.25}$: это такое число, что ровно 25% выборки меньше его (фактически это квантиль уровня 0,25).
- **2-ая квартиль** $Q_2 = X_{0.5}$: это такое число, что ровно 50% выборки меньше его (фактически это квантиль уровня 0,5 или медиана).
- **3-я квартиль** $Q_3 = X_{0.75}$: это такое число, что ровно 75% выборки меньше его (квантиль уровня 0,75).

Ящик с усами (боксплот)

График «ящик с усами», или «ящичковая диаграмма», или **диаграмма размаха** (**boxplot**, **boxplot**) – график, используемый в описательной статистике и компактно изображающий одномерное распределение вероятностей.



Такой вид диаграммы в удобной форме показывает медиану, нижний и верхний квартили, минимальное и максимальные значения выборки и выбросы.




Ящик с усами (боксплот)

Границами ящика служат первый и третий квартили (25-й и 75-й квартили соответственно), линия в середине ящика — медиана. Концы усов — края статистически значимой выборки (без выбросов) могут определяться:

$$X_H = Q_1 - k \cdot (Q_3 - Q_1); X_B = Q_3 + k \cdot (Q_3 - Q_1),$$


где X_H — нижняя граница уса, X_B — верхняя граница уса, Q_1 — первый квартиль, Q_3 — третий квартиль, k — коэффициент, наиболее часто употребляемое значение которого равно 1,5.

Данные, выходящие за границы усов (**выбросы**), отображаются на графике **в виде точек**, маленьких кружков или звёздочек.




Гистограммы

Одним из популярных способов визуализации одномерных выборок является **гистограмма**.



Гистограмма и Ящик с усами



Избавляться или нет от выбросов?

Что делать с выбросами?

1. **Удалить.** Выбросы следует **удалять** из выборки, потому что они "портят статистику". А статистика в целом работает с усредненными величинами. Удаление выбросов часто может улучшить соответствие набора данных требованию нормальности. И действительно, многие аналитики обычно удаляют экстремальные значения, потому что хотят исключить их влияние на расчеты средних значений.

Точно? А может быть, нас именно выбросы и интересуют?


Зависит от задачи исследования. Может быть, мы хотим исследовать людей с экстремальными значениями доходов (как нищих, так и миллиардеров) – скажем, чтобы проанализировать, как они дошли до жизни такой.

Избавляться или нет от выбросов?

2. **Заменить** менее экстремальными значениями ("сгладить").
можно использовать методы восстановления пропусков.

Наиболее широко используемыми вариантами для замены выбросов являются:

- медиана,
- среднее значение,
- можно взять, например, квантиль уровня 0,99 (или еще он называется 1-ый процентиль).



Преобразование данных

Если у аналитика или эксперта в изучаемой области есть уверенность, что полученные данные или их часть «должны» удовлетворять условию нормальности, а они таковыми не являются, есть методы приведения их к нормализованному виду для дальнейшей обработки и анализа с помощью статистических методов.

1) Логарифмирование переменных

$$X \rightarrow \ln(X)$$

Преобразовывая переменные, можно устранить выбросы, например, взяв натуральный логарифм значения. Таким образом уменьшается вариация, вызванная экстремальными значениями. Это можно сделать для наборов данных, которые не имеют отрицательных значений.

Преобразование данных

2) Нормализация данных (стандартизирование)

Иногда полезно применять нормализацию данных, что позволяет привести данные к единому масштабу.

Их можно использовать для того, чтобы описать отдельные значения показателя с помощью так называемых z-оценок. Это способ выразить любое значение переменной в количестве стандартных отклонений от среднего. С помощью z-оценок мы можем стандартизировать распределение – выразить все значения в терминах дистанции от среднего. Поэтому z-оценка еще называется стандартизированной.

Стандартизированная оценка (z-оценка, z-score) – это относительная мера, которая показывает, на сколько стандартных отклонений наблюдаемое значение отличается от среднего значения распределения.

- Знак z-оценки показывает, находится ли значение левее среднего (–) или правее среднего (+).

Стандартизированная оценка (z-оценка, z-score)

$$X \rightarrow Z = \frac{X - \bar{X}}{S_X}$$

Если преобразовать все значения показателя в распределении в z- оценки, то получим z-распределение или стандартизированное распределение.

Такое распределение сохранит форму оригинального распределения, но среднее в нем будет равно нулю, а среднеквадратичное отклонение – единице. Такая процедура еще называется стандартизацией распределения (z-преобразованием).

С помощью z-преобразования можно сравнивать показатели, имеющие значения в разных масштабах (шкалах). Это возможно за счет того, что среднее становится нулевым, а отклонение от среднего выражается не абсолютной величиной, а относительной (в единицах стандартного отклонения от среднего). То есть мы приводим данные к некоторому стандартному, универсальному представлению, «к общему знаменателю», и они становятся сопоставимы между собой.

Стандартизированная оценка (z-оценка, z-score)

Пример:

Представим, что нам нужно сравнить результаты тестирования двух групп студентов, которые сдавали разные экзамены по английскому языку.

Первая группа писала тест, оцениваемый по шкале от 0 до 9 баллов, а вторая – от 0 до 120.

С теми студентами, которые набрали максимальное количество баллов или наоборот умудрились получить 0, все просто. Их оценки мы можем сравнить друг с другом.

А в промежуточных случаях все не так очевидно: например, лучше оценка 60/120, чем 5/9?

Тут нам и помогут стандартизированные распределения. После того как мы найдем z-оценку для каждого оригинального значения переменной в двух группах, мы сможем сравнить оценки между собой.

Выявление выбросов с помощью z-оценок

Так как z-оценка показывает, на сколько сигм отклоняется значение от среднего, с помощью правила N сигма по z-оценке можно судить, не является ли оно выбросом.

Например, предположим, что приемная комиссия собирает статистику о заработной плате выпускников определенных факультетов для рекламной кампании.

Пусть 4 выпускника получают 35, 47, 50 и 68 тыс. руб. в месяц, а 5-ый – 250 тыс. Можно сразу интуитивно сказать, что значение 250 нетипично для выборки, но хорошо бы эту «нетипичность» формализовать: $\bar{X} = 90$, $S_X = 80,69$

Вычислим z-оценку, для этого определим среднее и стандартное отклонение выборки:

$$Z = \frac{X - \bar{X}}{S_X} = \frac{250 - 90}{80,69} = 1,98.$$

Зарплата в 250 тыс. еле попадает в диапазон сигма (95% всех наблюдений), но выходит за границы диапазона сигма (68% всех наблюдений).

Выявление выбросов с помощью z-оценок

Определение выбросов обычно субъективно, но есть некоторые конвенции (соглашения, договоренности между специалистами в той или иной предметной области). Например, значения за пределами диапазона называют сильными выбросами, а за пределами сигма – умеренными.


- Однако все это справедливо только если данные имеют нормальное распределение. Часто при анализе выборок делают такое допущение.



Центральная предельная теорема

Предположим, случайная величина имеет любое распределение с некоторым средним значением и стандартным отклонением.


Проведем эксперимент: будем многократно извлекать выборки объема из генеральной совокупности значений этой случайной величины. Выборки будут иметь разные числовые характеристики (описательные статистики – среднее и дисперсию).



Центральная предельная теорема

В каждой выборке вычислим среднее и построим распределение выборочных средних.

Оказывается, в пределе это распределение средних будет **нормальным**.



Центральная предельная теорема

ЦПТ. Предположим, показатель имеет любое распределение с некоторым средним и стандартным отклонением.

Распределение его выборочных средних будет нормальным с математическим ожиданием, равным $M(X)$ исходной генеральной совокупности, и стандартным отклонением $se = \frac{\sigma}{\sqrt{n}}$, где σ – стандартное отклонение исходной генеральной совокупности.

- Стандартное отклонение **se** называют **стандартной ошибкой среднего**. Она показывает, насколько в среднем выборочное среднее $\bar{X}$ отклоняется от математического ожидания (среднего генеральной совокупности).

Закон больших чисел: чем больше объем выборки, тем ближе выборочные средние к математическому ожиданию.

Центральная предельная теорема

Если выполняются следующие условия:

- выборка репрезентативна (элементы отобраны случайно, каждый элемент мог попасть в выборку с равной вероятностью, состав выборки отражает состав генеральной совокупности)
- число наблюдений в выборке $n > 30$

то формулу можно изменить, подставив вместо теоретического стандартного отклонения σ выборочное стандартное отклонение S_x :

$$se = \frac{\sigma}{\sqrt{n}}$$

Таким образом, уже только **по одной выборке** объема можно судить о том, как бы вели себя все выборочные средние: они бы распределились вокруг среднего генеральной совокупности с отклонением $se = \frac{\sigma}{\sqrt{n}}$

Основные распределения, используемые в статистике

Нормальное (Гауссовское) распределение

Такое распределение наиболее часто используется в тех случаях, когда на экономический результат оказывает влияние огромное число самых разнообразных факторов, среди которых нет сильно выделяющихся.

Нормальным ($N(a, \sigma^2)$) называют распределение вероятностей непрерывной случайной величины, которое описывается следующей плотностью вероятностей:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}}, \text{ где } x, a \in R, \sigma > 0.$$

График функции $f(x)$ имеет следующий вид




Рис. График плотности нормального распределения

График плотности нормального распределения называют *нормальной кривой*, или *кривой Гаусса*.

Функция $F(x)$ нормального распределения имеет вид

$$F(x) = \Phi\left(\frac{x-a}{\sigma}\right) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(z-a)^2}{2\sigma^2}} dz.$$

График функции распределения нормальной случайной величины имеет следующий вид:




Рис. График функции нормального распределения

Нормальное распределение определяется двумя параметрами: a и σ . Вероятностный смысл этих параметров таков: a — математическое ожидание, σ — среднее квадратичное отклонение нормального распределения, т.е. $M(X) = a$ и $\sigma(X) = \sigma$.

Замечание: Стандартным нормальным или нормированным называют нормальное распределение с параметрами $a = 0$ и $\sigma = 1$. Например, если X – нормальная величина с параметрами a и σ , то $U = (X - a)/\sigma$ – стандартная нормальная величина, причем $M(U) = 0$ и $\sigma(U) = 1$. Плотность стандартного нормального распределения имеет вид

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}.$$

Данная функция табулирована (см. приложение).

Функция распределения $\Phi(x)$ стандартного нормального распределения имеет вид

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{z^2}{2}} dz.$$

Функция $\Phi(x)$ табулирована (см. приложение). Функция $\Phi(x)$ имеет свойство: $\Phi(-x) = 1 - \Phi(x)$.

Влияние параметров нормального распределения на форму нормальной кривой

Изменение величины параметра a (математического ожидания) не изменяет формы нормальной кривой, а приводит лишь к ее сдвигу вдоль оси Ox : вправо, если a возрастает, и влево, если a убывает:




Рис. График плотности нормального распределения при различных параметрах

Максимум функции плотности вероятностей нормального распределения равен $\frac{1}{\sigma\sqrt{2\pi}}$. Отсюда следует, что с возрастанием σ максимальная ордината нормальной кривой убывает, а сама кривая становится более полой, т.е. сжимается к оси Ox ; при убывании σ нормальная кривая становится более «островершинной» и растягивается в положительном направлении оси Oy :




Рис. 13. График плотности нормального распределения при различных параметрах

Замечание: При любых значениях параметров a и σ площадь, ограниченная нормальной кривой и осью Ox , остается равной единице.

Распределение хи-квадрат

Пусть $Z_i \sim N(0;1)$, $i = 1, 2, \dots, k$, тогда случайная величина $\chi^2 = \sum_{i=1}^k X_i^2$ называется величиной, распределенной по закону χ^2 с k степенями свободы. Плотность хи-квадрат распределения изображена на рис.




Рис. Плотность распределения хи-квадрат с k степенями свободы

Плотность распределения хи-квадрат имеет вид

$$f_{\chi^2}(x) = \begin{cases} 0, & \text{если } x \leq 0 \\ \frac{1}{2^{k/2} \cdot \Gamma(k/2)} \cdot e^{-\frac{x}{2}} \cdot x^{\frac{k}{2}-1}, & \text{если } x > 0 \end{cases}$$

где $\Gamma(x) = \int_0^{+\infty} t^{x-1} \cdot e^{-t} \cdot dt$ – гамма-функция, причем $\Gamma(k+1) = k!$ Параметры хи-квадрат распределения следующие: $M[\chi^2(k)] = k$, $D[\chi^2(k)] = 2k$. Распределение χ^2 определяется одним параметром – числом степеней свободы. С увеличением степеней свободы распределение χ^2 медленно приближается к нормальному. На практике при $k > 30$ считают, что $\chi^2 \sim Y$, где $Y \sim N(k, \sqrt{2k})$. Для случайной величины, имеющей χ^2 распределение, существуют таблицы квантилей (табл. А4).

Распределение Стьюдента

Рассмотрим случайную величину

$$t = \frac{Z}{\sqrt{\frac{1}{k} \chi^2}},$$

где $Z \sim N(0; 1)$ – нормально распределенная случайная величина с математическим ожиданием, равным 0, и дисперсией, равной 1, χ^2 – не зависящая от Z случайная величина, имеющая распределение хи-квадрат с k степенями свободы. Эта случайная величина имеет *распределение Стьюдента* с k степенями свободы.

Распределение Стьюдента симметрично относительно начала координат и зависит только от одного параметра – от числа степеней свободы k . Функция плотности распределения Стьюдента имеет вид

$$f(x) = \frac{\Gamma\left(\frac{k+1}{2}\right)}{\Gamma\left(\frac{k}{2}\right)\sqrt{\pi k}} \left(1 + \frac{x^2}{k}\right)^{-\frac{k+1}{2}},$$

где $\Gamma(k)$ – гамма-функция. График плотности распределения Стьюдента с $k = 1$ и $k = 5$ приведен на рис.




Рис. Плотность распределения Стьюдента с k степенями свободы

Распределение Фишера

Если U и V – независимые случайные величины, распределенные по закону χ^2 , $U \sim \chi^2(k_1)$, $V \sim \chi^2(k_2)$, тогда

величина $F = \frac{U/k_1}{V/k_2}$ имеет распределение, которое называется F -распределением, или распределением


Фишера со степенями свободы k_1 и k_2 . ($F \sim F(k_1, k_2)$). Плотность распределения Фишера имеет вид

$$f_F(x) = \begin{cases} 0, & x \leq 0 \\ \frac{\Gamma\left(\frac{k_1+k_2}{2}\right)}{\Gamma\left(\frac{k_1}{2}\right) \cdot \Gamma\left(\frac{k_2}{2}\right)} \cdot \left(\frac{k_1}{k_2}\right)^{\frac{k_1}{2}} \cdot \frac{x^{\frac{k_1}{2}-1}}{\left(1 + \frac{k_1}{k_2}x\right)^{\frac{k_1+k_2}{2}}}, & \text{если } x > 0 \end{cases} \quad m_F = \frac{k_2}{k_1 - 2}, \quad k_2 > 2$$

F -распределение определяется двумя

параметрами k_1 и k_2 и существует таблица квантилей. $F_{1-p}(k_1, k_2) = \frac{1}{F_p(k_1, k_2)}$. Квантили распределения

имеются в табл. А5 и А6. На рис. изображена плотность распределения Фишера с k_1 и k_2 степенями свободы.



**Рис. График плотности распределения Фишера
с k_1 и k_2 степенями свободы**

Распределение Фишера находит широкое применение в задачах дисперсионного анализа, например, в задачах проверки гипотез о равенстве или различии дисперсий.

Интервальное оценивание

Иногда бывает необходимо знать интервал (α, β) , в котором с достаточно большой степенью уверенности γ (0,9; 0,95; 0,999,...) может находиться неизвестное значение числовой характеристики θ . То есть при заданном уровне надёжности γ по имеющейся выборке $X_1, X_2, \dots, X_n$ надо определить границы интервала α и β так, чтобы выполнялось неравенство $P(\alpha < \theta < \beta) \geq \gamma$.

Вероятность γ называется **доверительной вероятностью**, а интервал (α, β) — **доверительным интервалом**.

Виды доверительных интервалов:

Двусторонний (α, β)

правосторонний $(-\infty, \beta)$

левосторонний $(\alpha, +\infty)$

**Доверительные интервалы для параметров
нормальной совокупности**

Пусть есть некоторая выборка $X_1, X_2, \dots, X_n$, представляющая собой n независимых повторных наблюдений над этой случайной величиной, которая имеет нормальное распределение $X \sim N(a, \sigma^2)$, где $M[X] = a$ и $D[X] = \sigma^2$.

**Доверительный интервал для неизвестного $M[X] = a$
нормальной совокупности при известной $D[X] = \sigma^2$**

тогда двусторонний доверительный интервал

$$\bar{X} - t_{\gamma}[N] \cdot \frac{\sigma}{\sqrt{n}} \leq a \leq \bar{X} + t_{\gamma}[N] \cdot \frac{\sigma}{\sqrt{n}} ;$$

левосторонний доверительный интервал $a \geq \bar{X} - x_{\gamma}[N] \cdot \frac{\sigma}{\sqrt{n}} ;$

правосторонний доверительный интервал $a \leq \bar{X} + x_{\gamma}[N] \cdot \frac{\sigma}{\sqrt{n}} .$

**Доверительный интервал для неизвестного $M[X] = a$
нормальной совокупности при неизвестной $D[X] = \sigma^2$**

Двусторонний доверительный интервал

$$\bar{X} - t_{\gamma}[St(n-1)] \cdot \frac{S_x}{\sqrt{n-1}} \leq a \leq \bar{X} + t_{\gamma}[St(n-1)] \cdot \frac{S_x}{\sqrt{n-1}}.$$

Левосторонний доверительный интервал

$$a \geq \bar{X} - x_{\gamma}[St(n-1)] \cdot \frac{S}{\sqrt{n-1}}.$$

Правосторонний доверительный интервал

$$a \leq \bar{X} + x_{\gamma}[St(n-1)] \cdot \frac{S}{\sqrt{n-1}}.$$

**Доверительный интервал для неизвестной дисперсии $D[X] = \sigma^2$ нормальной
совокупности при известном $M[X] = a$**

Двусторонний доверительный интервал

$$\frac{nS^2}{\frac{x_{1+\gamma}}{2}[\chi^2(n-1)]} < \sigma^2 < \frac{nS^2}{\frac{x_{1-\gamma}}{2}[\chi^2(n-1)]}.$$

Правосторонний доверительный интервал $\sigma^2 < \frac{n \cdot S_x^2}{x_{1-\gamma}[\chi^2(n-1)]}$ *Левосторонний*

доверительный интервал $\frac{n \cdot S_x^2}{x_\gamma[\chi^2(n-1)]} < \sigma^2.$

Доверительный интервал для математического ожидания

Если $X_1, \dots, X_n$ – независимые одинаково распределенные случайные величины,

Двусторонний доверительный интервал для математического ожидания генеральной совокупности, закон распределения которой неизвестен, имеет вид

$$\bar{X} - t_{\gamma}[N] \cdot \frac{S_x}{\sqrt{n}} \leq M[X] \leq \bar{X} + t_{\gamma}[N] \cdot \frac{S_x}{\sqrt{n}}.$$

Левосторонний доверительный интервал

$$M[X] \geq \bar{X} - x_{\gamma}[N] \cdot \frac{S_x}{\sqrt{n}}.$$

Правосторонний доверительный интервал $M[X] \leq \bar{X} + x_{\gamma}[N] \cdot \frac{S_x}{\sqrt{n}}.$

Доверительный интервал для вероятности

Приближенный двусторонний доверительный интервал для вероятности появления события, построенный по результатам n независимых повторных испытаний, в которых событие проявилось m раз, имеет вид

$$w - t_\gamma[N] \cdot \sqrt{\frac{w(1-w)}{n}} \leq p \leq w + t_\gamma[N] \cdot \sqrt{\frac{w(1-w)}{n}},$$

где $w = \frac{m}{n}$ — относительная частота события.

Левосторонний доверительный интервал $w - x_\gamma[N] \cdot \sqrt{\frac{w(1-w)}{n}} \leq p.$

Правосторонний доверительный интервал $p \leq w + x_\gamma[N] \cdot \sqrt{\frac{w(1-w)}{n}}.$

Доверительный интервал для доли совокупности

Пусть N — объем генеральной совокупности, n — объем бесповторной выборки из генеральной совокупности, m — количество элементов в выборке, обладающих заданным свойством, D — количество элементов в генеральной совокупности, обладающих заданным свойством.

Двусторонний доверительный интервал для доли D/N в генеральной совокупности элементов с заданным свойством имеет вид

$$w - t_\gamma[N] \cdot \sqrt{\frac{w(1-w)(N-n)}{n(N-1)}} \leq \frac{D}{N} \leq w + t_\gamma[N] \cdot \sqrt{\frac{w(1-w)(N-n)}{n(N-1)}},$$

где $w = \frac{m}{n}$ — относительная частота события.

Левосторонний доверительный интервал $w - t_\gamma[N] \cdot \sqrt{\frac{w(1-w)(N-n)}{n(N-1)}} \leq \frac{D}{N}$.

Правосторонний доверительный интервал

$$\frac{D}{N} \leq w + t_\gamma[N] \cdot \sqrt{\frac{w(1-w)(N-n)}{n(N-1)}}.$$