

Регрессионный анализ

Регрессионный анализ представляет собой анализ форм связи, устанавливающих количественные соотношения между случайными величинами изучаемого случайного процесса.

Это совокупность методов для определения аналитической формы зависимости результативного признака от одного или нескольких факторных признаков

Регрессионный анализ — совокупность методов анализа связей между различными показателями (факторами) на основании реальных статистических данных с использованием аппарата теории вероятностей и математической статистики. Применение этих методов позволяет придавать конкретное количественное выражение общим (качественным) закономерностям

Основные переменные

Y – основной экономический показатель, поведение которого изучается (зависимая, целевой показатель, объясняемая, выходная, результирующая, эндогенная, случайная переменная, результирующий признак, эндогенная переменная, отклик)

$X_1, \dots, X_m$ – экономические показатели (независимые переменные, экзогенные переменные, факторы), которые оказывают (а возможно и нет, исследователь тоже может ошибаться) влияние на поведение Y (объясняющие, входные, предсказывающие, экзогенные, неслучайные переменные, факторы, регрессоры, факторные признаки)

в том случае, когда в модели будет только одна независимая переменная, вместо $X_1, \dots, X_m$ в целях упрощения будет использоваться обозначение X

t – независимая переменная, интерпретируемая как время;

ε – случайные компоненты регрессионной модели (используются для описания эффекта влияния тех экономических показателей и внешних обстоятельств, учесть влияние которых не представляется возможным или целесообразным)

Виды связи между переменными

1. Функциональные: $Y = f(X)$

Имеют место при исследовании связей между неслучайными переменными. Такие связи в эконометрике не рассматриваются.

При функциональной зависимости каждому значению независимой переменной x однозначно соответствует вполне определенное значение зависимой переменной y . Эту зависимость можно описать в виде равенства $Y = f(X)$

Пример: $Y = 2 + 3X$

2. Стохастические (статистические): изменение одной из величин влечет изменение закона распределения другой или каждому значению одной переменной соответствует определенное (условное) распределение другой переменной, т.е. когда каждому значению одной переменной соответствует не какое-то определенное, а множество возможных значений другой переменной

При стохастической зависимости для заданных значений независимой переменной X можно указать ряд значений Y , случайно рассеянных в интервале.

Каждому фиксированному значению аргумента соответствует определенное статистическое распределение значений функции. Это связано с тем, что зависимая переменная, кроме выделенной переменной X , подвержена влиянию также других неконтролируемых или неучтенных факторов, а также с тем, что накладываются ошибки измерения.

Поскольку значения зависимой переменной подвержены случайному разбросу, они не могут быть предсказаны с достаточной точностью, а только указаны с определенной вероятностью.

Например, мы знаем, что прибыль коммерческого банка определенным образом связана с размером его уставного капитала (этот факт не подлежит сомнению). Тем не менее, нельзя вычислить точную величину прибыли при заданном значении последнего показателя, так как она зависит еще и от множества других факторов, помимо размера уставного капитала, среди которых имеются и случайные.

Виды стохастической (статистической) зависимости:

- а) **Корреляционные:** при изменении одной из величин изменяется среднее значение другой (связь между переменными не носит направленного характера)
- б) **Регрессионные:** односторонняя зависимость среднего значения случайной величины Y от одной X или нескольких $X_1, \dots, X_m$ случайных величин.

Регрессия (функция регрессии)

Регрессия (функция регрессии) – это функция, характеризующая зависимость среднего значения зависимой переменной Y от значений объясняющих переменных $X_1, \dots, X_m$

$$M(Y | X_1, X_2, \dots, X_k) = f(X_1, X_2, \dots, X_k, \beta) \equiv Y_X$$

$f(X_1, X_2, \dots, X_k, \beta)$ – это некоторая неслучайная функция, известная с точностью до одномерного или многомерного параметра β .

Неизвестный параметр (одномерный или многомерный) $\beta = (b_0, b_1, \dots, b_k)^T$.

Вместо обозначения среднего уровня будем использовать запись Y_X

Термин "регрессия" в статистике впервые был использован Френсисом Гальтоном (1886) в связи с исследованием вопросов наследования физических характеристик человека.

- В качестве одной из характеристик был взят рост человека; при этом было обнаружено, что в целом сыновья высоких отцов оказались более высокими, чем сыновья отцов с низким ростом.
- Более интересным было то, что разброс в росте сыновей был меньшим, чем разброс в росте отцов.
- Так проявлялась тенденция возвращения роста сыновей к среднему (regression to mediocrity), то есть «регресс».

Этапы построения регрессионных моделей:

1. **Постановочный этап.** Определение конечных целей моделирования, набора участвующих в модели факторов и показателей, их роли.
2. **Априорный этап.** Предмодельный анализ экономической сущности изучаемого явления, формирование и формализация априорной информации, в частности, относящихся к природе и генезису исходных статистических данных и случайных составляющих.
3. **Спецификация модели.** Выбор общего вида модели, в том числе состава и формы входящих в нее связей.
4. **Информационный этап.** Сбор необходимой статистической информации, т.е. измерение значений участвующих в модели факторов и показателей изучаемого явления.
5. **Идентификация модели.** Статистический анализ модели и в первую очередь статистическое оценивание неизвестных параметров модели.
6. **Верификация модели.** Сопоставление модельных и реальных данных, проверка адекватности модели, оценка точности модельных данных

Использование модели для анализа и прогнозирования

Виды регрессионных моделей

1. **Аддитивные** $Y = Y_x + \varepsilon$

2. **Мультипликативные** $Y = Y_x \cdot \varepsilon$

где ε – **случайный фактор (ошибка, погрешность)**, обусловленный многими причинами.

ε – случайные компоненты регрессионной модели (используются для описания эффекта влияния тех экономических показателей и внешних обстоятельств, учесть влияние которых не представляется возможным или целесообразным)

Причины обязательного присутствия случайного фактора ε

- Невключение в модель всех объясняющих переменных. **Пропущенные переменные (omitted variables, неучтенные факторы)**
- **Неправильная спецификация (ошибки спецификации** - Неправильный выбор функциональной формы модели.
- Агрегирование переменных (факторы представляют собой комбинацию других переменных).
- Ошибки измерений.
- Ограниченность статистических данных.

И другие...

Виды регрессионных зависимостей

По количеству переменных в модели:

Парные регрессионные модели отражают зависимость одного результирующего признака Y от одной независимой переменной X .

Пример 1. Мы хотим определить зависимость между продажами и затратами на рекламу.

- y – продажи
- x – рекламные расходы.

Множественная регрессия – зависимость одного результирующего признака Y от нескольких объясняющих переменных $X_1, \dots, X_m$

Пример 2. Мы хотим определить связь между потреблением, доходом семьи, финансовыми активами семьи и размером семьи.

- y – потребительские расходы
- x_1 – доход семьи
- x_2 – финансовые активы семьи
- x_3 – размер семьи

По форме	
Линейные по параметрам	Парная линейная регрессионная модель $Y = a + bX + \varepsilon$
	Парная гиперболическая регрессионная модель $Y = a + \frac{b}{X} + \varepsilon$
	Парная квадратичная регрессионная модель $Y = a + bX + cX^2 + \varepsilon$
	Множественная линейная регрессионная модель $Y = b_0 + b_1X_1 + b_2X_2 + \dots b_kX_k + \varepsilon$
Нелинейные по параметрам	Показательная регрессионная модель $Y = ab^X \varepsilon$
	Экспоненциальная регрессионная модель $Y = ae^{bX} \varepsilon$
	Степенная регрессионная модель $Y = aX^b \varepsilon$

Парный регрессионный анализ

Случайная выборка из n наблюдений переменной x и n наблюдений переменной y . **n пар наблюдений** $(x_i, y_i) \ i=1, 2, \dots, n$

В модели парной линейной регрессии зависимость между переменными Y и X представляется в виде следующей формулы:

$$Y = a + bX + \varepsilon,$$

где ε – случайная ошибка модели (**error**, или **disturbance**).


Постоянные a, b – неизвестные параметры модели. Наличие случайного члена ε связано с воздействием на зависимую переменную Y других факторов, не учтенных в функции регрессии, с возможной нелинейностью модели и ошибками измерения.

В данной модели функция регрессии является линейной функцией: $Y_x = a + bX$.

Как выбрать??

Корреляционное поле (диаграмма рассеивания)– график, на котором результаты n наблюдений

переменных X и Y изображаются в виде точек в декартовой системе координат.




а) Взаимосвязь между Y и X близка к линейной: $Y = a + bX$

б) Взаимосвязь близка к квадратической: $Y = a + bX + cX^2$

в) Взаимосвязь между Y и X отсутствует. Какую бы мы ни выбрали форму связи, результаты проверки ее качества будут неудачными

Пример

Модель линейной регрессии является наиболее распространенной (и простой) зависимостью между переменными, а также может служить начальной точкой регрессионного анализа



Метод наименьших квадратов в случае парной линейной регрессионной модели

Рассмотрим задачу нахождения оценок неизвестных параметров a, b модели по результатам наблюдений $(x_i, y_i), i = 1, \dots, n$.

Если исследуемые переменные X и Y связаны соотношением $Y = a + bX + \varepsilon$, то и результаты наблюдений связаны аналогичными соотношениями $y_i = a + bx_i + \varepsilon_i$, где ε_i – случайная ошибка i -го наблюдения.

Чем меньше ε_i , тем ближе значение функции регрессии $a + bx_i$ к значению y_i . Будем искать такие значения a и b , при которых одновременно все значения ε_i «достаточно малы». В этом случае значения линейной функции регрессии $Y_x = a + bX$ окажутся близкими к соответствующим значениям зависимой переменной Y . Для решения этой проблемы воспользуемся методом наименьших квадратов (МНК). В соответствии с МНК определяем такие значения параметров a, b , при которых достигает своего минимального значения сумма квадратов

ошибок модели в n наблюдениях:
$$Q = Q(a, b) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - a - bx_i)^2.$$

Метод наименьших квадратов в случае парной линейной регрессионной модели

Система нормальных уравнений служит для определения оценок неизвестных параметров линейной регрессии

$$\begin{cases} an + b \sum_{i=1}^n x_i = \sum_{i=1}^n y_i, \\ a \sum_{i=1}^n x_i + b \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i. \end{cases}$$

Оценки параметров модели, найденные МНК

$$\begin{cases} \hat{b} = \frac{K_*(X, Y)}{S_X^2} = r_*(X, Y) \frac{S_Y}{S_X} \\ \hat{a} = \bar{Y} - \hat{b}\bar{X} \end{cases}$$

Статистики $\hat{a}$, $\hat{b}$ называются *оценками наименьших квадратов (least squares estimates)* неизвестных параметров a и b , или *LS-оценками*

Оценка функции регрессии (эмпирическая регрессия, выборочная регрессия)

$$\hat{Y}_X = \hat{a} + \hat{b}X$$

Интерпретация найденных параметров

$\hat{a}$ Дает оценку среднего значения зависимой переменной при $X = 0$. Эта интерпретация возможна или невозможна в зависимости от того, насколько далеко находится $X = 0$ от выборочных значений X
Часто не имеет интерпретации

$\hat{b}$ Оценка коэффициента регрессии. Он показывает, на сколько единиц в среднем изменится переменная Y при увеличении независимой переменной X на единицу

Множественная регрессионная модель

Обобщением линейной регрессионной модели с одной объясняющей переменной является линейная регрессионная модель с k объясняющими переменными (**модель множественной линейной регрессии**):

$$Y = b_0 + b_1 X_1 + \dots + b_k X_k + \varepsilon, \quad (1)$$

n – число наблюдений

Y – зависимая переменная (эндогенная). Величина, закономерность поведения которой следует определить.

ε – случайная составляющая, случайное возмущение, шум, шок, ошибка

$b_0, b_1, \dots, b_k$ – коэффициенты регрессии, неизвестные параметры

МНК для множественной регрессии:

Определить такие значения $b_0, b_1, \dots, b_k$, при которых достигает своего минимального значения сумма квадратов ошибок модели в n наблюдениях:

$$Q = Q(a, b) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_{i1} - b_2 x_{i2} - \dots b_k x_{ik})^2$$

Оценки параметров модели, найденные МНК $\hat{\beta} = (X^T X)^{-1} X^T Y$

Оценка функции регрессии (эмпирическая регрессия, выборочная регрессия)

$$\hat{Y}_X = \hat{b}_0 + \hat{b}_1 X_1 + \dots + \hat{b}_k X_k$$

Верификация модели. Показатели качества модели и параметров регрессии

После нахождения оценки модели возникает вопрос о том, насколько хорошо эта оценка соответствует функции регрессии.

Такую задачу называют проверкой качества найденного уравнения регрессии.

Для решения этой проблемы используют в первую очередь такие распространенные статистики, как **регрессионные остатки**

модели, определяемые выражениями: $e_i = y_i - \hat{y}_i$, где y_i — реальные значения зависимой переменной, $\hat{y}_i$ — расчетные значения

Показатели качества модели и параметров регрессии

$TSS = nS_Y^2 = \sum_{i=1}^n (y_i - \bar{y})^2$	<i>Полная сумма квадратов (total sum of squares)</i> характеризует общую изменчивость зависимой переменной
$ESS = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$	<i>Сумма квадратов, объясненная моделью (explained sum of squares) или факторной суммой квадратов</i> , определяет ту часть <i>TSS</i> , которую позволяет объяснить предложенная модель
$RSS = \sum_{i=1}^n e_i^2$	<i>Остаточная сумма квадратов (residual sum of squares)</i> определяет ту часть вариации, которую не позволяет объяснить предложенная модель
$TSS = ESS + RSS$	Основное тождество дисперсионного анализа
$\hat{\sigma}^2 = \frac{RSS}{n - m}$	<i>Оценка дисперсии (ошибки) модели</i> – несмещенная оценка дисперсии ошибки модели. <i>m</i> - число параметров модели (в рассматриваемом случае это параметры <i>a</i> и <i>b</i> поэтому <i>m</i> =2).

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2}$$

Стандартная ошибка модели

Стандартные ошибки оценок коэффициентов регрессии являются оценками среднего квадратичного отклонения коэффициентов регрессии от его истинного значения

$$S_{\hat{b}_i} \quad \text{или} \quad SE(\hat{b}_i)$$

Коэффициент детерминации

Коэффициент детерминации определяет долю дисперсии зависимой переменной, объясненную эмпирической функцией регрессии.

$$R^2 = 1 - \frac{RSS}{TSS} = \frac{ESS}{TSS}$$

По этой причине коэффициент детерминации является основной мерой качества подгонки регрессионной модели к данным с помощью выборочного уравнения регрессии.

Свойства:

1. $R^2 \in [0; 1]$
2. Чем ближе R^2 к единице, тем выше качество подгонки зависимой переменной с помощью выбранной регрессионной модели и тем более точно функция $\hat{y}_x$ аппроксимирует поведение Y с учетом изменения независимой переменной x . Другими словами: тем лучше регрессия

аппроксимирует статистические данные, тем теснее линейная связь между зависимой и объясняющими переменными.

3. Для простейшей парной линейной регрессионной модели (какую мы и рассматриваем) коэффициент детерминации равен квадрату коэффициента корреляции: $R^2 = r_*^2(X, Y)$
4. $R^2 = r_*^2(Y, \hat{Y})$ – коэффициент детерминации равен квадрату выборочного коэффициента корреляции $r_*(Y, \hat{Y})$ между зависимой переменной Y и ее оценкой $\hat{Y}$, где $\hat{Y}$ равно $\hat{Y} \equiv \hat{Y}_X = \hat{b}_0 + \hat{b}_1 X_1 + \hat{b}_2 X_2 + \dots + \hat{b}_k X_k$
5. Величину $R = r_*(Y, \hat{Y}) = \sqrt{R^2}$ принято называть *множественным коэффициентом корреляции (multiple-R)*. Чем ближе его значение к единице, тем в большей степени можно считать, что имеющиеся данные связаны множественной линейной регрессионной зависимостью
6. Вычисление R^2 корректно, если константа b_0 включена в уравнение регрессии
7. Коэффициенты R^2 в разных моделях с разным числом наблюдений несравнимы

8. Если $R^2 = 0$, то вариация зависимой переменной полностью обусловлена воздействием неучтенных в модели переменных
9. Если $R^2 = 1$, то статистические данные лежат на линии регрессии, т.е. между зависимой и объясняющими переменными имеется функциональная зависимость
10. Высокий R^2 не гарантирует высокое качество модели. Есть риск ложной регрессии
11. Низкий R^2 говорит о том, что важные существенные факторы, которые мы не учли в модели
12. Известно, что включение в модель одной или нескольких новых переменных может привести только к увеличению R^2 . Коэффициент детерминации не может уменьшиться даже при включении в модель несущественных переменных. Более того, включением в модель достаточно большого числа переменных можно добиться того, что значение коэффициента детерминации станет равным единице

Скорректированный коэффициент детерминации

Поскольку каждый раз при добавлении в модель новой независимой переменной доля объясненной дисперсии зависимой переменной возрастает, логично было бы включить в модель как можно больше переменных. Но на практике данный подход не дает хороших результатов, поскольку не гарантирует, что будут выбраны именно те переменные, которые вносят значимый вклад в долю объясненной дисперсии.

Скорректированный коэффициент детерминации позволяет решить данную проблему, поскольку вводит штраф модели, который увеличивается при добавлении каждой переменной. Если исходный коэффициент детерминации непрерывно возрастает при добавлении каждой независимой переменной, то скорректированный сначала также возрастает, а потом начинает уменьшаться из-за того, что возрастание штрафа начинает «перевешивать» рост объясненной доли дисперсии. Тогда лучшей будет та модель, для которой значение скорректированного коэффициента детерминации максимально.

Скорректированный коэффициент детерминации

$$R_{adj}^2 = 1 - \frac{n-1}{n-m} \cdot \frac{RSS}{TSS} = 1 - \frac{n-1}{n-m} (1 - R^2)$$
 – это коэффициент детерминации с поправкой на число степеней свободы

Свойства скорректированного коэффициента детерминации

1. $R_{adj}^2 \in [0; 1]$
2. Если увеличение доли объясненной регрессии при добавлении новой переменной мало, то скорректированный коэффициент детерминации может уменьшиться, следовательно, добавлять переменную нецелесообразно
3. $R_{adj}^2 < R^2$ при $n > m$ и $m > 1$
4. При использовании коэффициента R_{adj}^2 для выбора между конкурирующими моделями лучшей признается та из них, для которой этот коэффициент принимает максимальное значение

Информационные критерии

Информационный критерий Акаике (*Akaike's information criterion – AIC*)

$$AIC = \ln\left(\frac{RSS}{n}\right) + \frac{2k}{n}$$

Применяется для выбора между несколькими альтернативными моделями, а также «штрафует» за увеличение количества объясняющих переменных в модели.

Информационный критерий Шварца (*Schwarz's information criterion – SC, SIC*)

$$SC = \ln\left(\frac{RSS}{n}\right) + \frac{k \ln n}{n}$$

Среди нескольких альтернативных моделей предпочтение отдается модели с наименьшим значением AIC и SC , в которой достигается определенный компромисс между величиной остаточной суммы квадратов и количеством объясняющих переменных

Проверка значимости всей модели (Критерий Фишера)

С целью анализа совокупной значимости коэффициентов уравнения линейной регрессии проверяют гипотезу о статистической значимости коэффициента детерминации.

Гипотеза H_0 : (модель в целом незначима, неадекватна)

H_1 : модель в целом значима.

Для проверки этой гипотезы используется F -статистика следующего вида:

$$F = \frac{R^2}{1 - R^2} \cdot \frac{n - m}{k},$$

Критическое значение F -статистики определяется по табл. А5 и А6:
 $K_{таб} = \chi_{1-\alpha}^2[F(k, n - m)]$.

Если $K_{выч} > K_{таб}$, то гипотезу о значимости модели H_1 следует принять, а гипотезу H_0 отклонить.

Проверка значимости параметров модели (критерий Стьюдента)

$H_0 : b_i = 0$ (*коэффициент незначим*) – генеральный параметр регрессии равен нулю (или иначе: коэффициент регрессии генеральной совокупности незначим) (*statistically insignificant*)

$H_1 : b_i \neq 0$ (*коэффициент значим*) – о том, что генеральный коэффициент регрессии значим (*statistically significant*)

Для решения этой задачи используется t-статистика следующего вида:

$$K_{\text{выч}} = t\text{-statistics} = \frac{\hat{b}_i}{S_{\hat{b}_i}}.$$

Вычисленное по этой формуле при заданном уровне значимости α значение статистики $K_{\text{выч}}$ сравнивается с табличным значением $K_{\text{таб}} = t_{1-\alpha}[St(n-m)]$.

Если выполняется неравенство $|K_{\text{выч}}| < K_{\text{таб}}$, то нет оснований отклонить нулевую гипотезу. Если выполняется противоположное неравенство $|K_{\text{выч}}| \geq K_{\text{таб}}$, то с вероятностью $1-\alpha$ принимается альтернативная гипотеза.

Определение величины вклада независимых переменных в результат

По коэффициентам регрессии $b_1, b_2, \dots, b_k$ обычно невозможно определить, какой из факторов $X_1, X_2, \dots, X_k$ оказывает наибольшее влияние на зависимую переменную, так как коэффициенты регрессии между собой несопоставимы (они, как правило, имеют различную размерность).

- 1) **Частные средние коэффициенты эластичности.** Частный коэффициент показывает, на сколько процентов в среднем изменится зависимая переменная с увеличением на 1% определенного фактора X_i при фиксированном значении других факторов. Его значение рассчитывается по формуле

$$\bar{\varepsilon}_i = \hat{b}_i \frac{\bar{X}_i}{\bar{Y}_i}, \text{ где } \bar{X}_i - \text{среднее значение изучаемого фактора } X_i.$$

2) Сопоставление эффектов влияния на результат различных факторов может быть осуществлено также с помощью **стандартизованных коэффициентов регрессии (или бэта-коэффициентов)**. Бэта-коэффициент a_i показывает, на сколько величин S_Y изменится в среднем зависимая переменная Y при увеличении только одной i -й объясняющей переменной X_i на S_{X_i} :

$$a_i = \hat{b}_i \frac{S_{X_i}}{S_Y}$$

Бэта-коэффициенты позволяют получить оценку функции множественной линейной регрессии в **нормированной форме**:

$$\frac{\hat{Y}_X - \bar{Y}}{S_Y} = a_1 \cdot \frac{X_1 - \bar{X}_1}{S_{X_1}} + \dots + a_k \cdot \frac{X_k - \bar{X}_k}{S_{X_k}} .$$

3) Парный коэффициент корреляции

4) Частный коэффициент корреляции

Предпосылки линейной регрессии (условия Гаусса-Маркова)

Наиболее содержательные и точные выводы относительно модели

$$Y = b_0 + b_1 X_1 + \dots + b_k X_k + \varepsilon,$$

по результатам наблюдений могут быть получены при следующих предположениях (условиях Гаусса-Маркова, исключая п. 6).

Модель должна быть линейная по параметрам правильно специфицирована.

- 1. Значения $x_1, \dots, x_n$ являются неслучайными величинами.*
- 2. Математическое ожидание случайной ошибки в каждом наблюдении равно нулю, то есть $M(\varepsilon_i) = 0$, $i = \overline{1, n}$.*

В среднем ошибки не влияют на зависимую переменную Y .

Предпосылки линейной регрессии (условия Гаусса-Маркова)

3. *Дисперсия случайной ошибки постоянна для всех наблюдений, то есть*

$$D(\varepsilon_i) = M(\varepsilon_i^2) = \sigma^2, \quad i = \overline{1, n}.$$

Условие *постоянства дисперсии* случайной ошибки называют также гомоскедастичностью случайных ошибок. *Зависимость* дисперсии случайной ошибки от номера наблюдения называется гетероскедастичностью.

4. *Случайные ошибки различных наблюдений статистически не связаны (некоррелированы) между собой, то есть $M(\varepsilon_i \varepsilon_j) = 0$ при $i \neq j$.*

Четвертое условие указывает на некоррелированность случайных ошибок для разных наблюдений. Это условие часто нарушается, когда исходные данные являются временными рядами. В этом случае говорят об автокорреляции случайных ошибок.

5. Отсутствие полной (совершенной) мультиколлинеарности

6. *Случайные ошибки имеют совместное нормальное распределение, в частности $\varepsilon_i \in N(0; \sigma^2)$.*

При выполнении этих условий модель будем называть **классической линейной регрессионной моделью наблюдений**.

Теорема Гаусса-Маркова

Главным основанием для широкого использования МНК-оценок является следующее утверждение.

Теорема Гаусса-Маркова.

Если для модели $Y = b_0 + b_1X_1 + \dots + b_kX_k + \varepsilon$, выполняются условия 1-5, то оценки неизвестных параметров, найденные с помощью МНК, являются наилучшими линейными несмещенными оценками (*BestLinearUnbiasedEstimator*, или *BLUE*) параметров

Проверка основных предположений регрессионного анализа

2. Математическое ожидание случайной ошибки в каждом наблюдении равно нулю, то есть $M(\varepsilon_i) = 0, i = \overline{1, n}$.

Можно проверить с помощью критерия, описанного в прошлой лекции

3. Гомоскедастичность ошибок

- Гомоскедастичность (постоянство дисперсии) ошибок заключается в том, что разброс остатков при любых значениях независимых переменных одинаков.

Если это условие не соблюдается, то имеет место гетероскедастичность (heteroscedasticity). Вместо термина «гетероскедастичная модель» часто используют термин «модель с неравноточными наблюдениями».

В случае гетероскедастичной модели МНК-оценки коэффициентов регрессии оказываются хотя и несмещенными, но неэффективными.

Гетероскедастичность ошибок

Пример.

Предположим, что мы хотим предсказать стоимость квартиры по каким-то ее признакам.


$$P_{\text{квартиры}} = f(\text{параметров})$$

Очень маленькие квартиры	Очень большие квартиры
Стоят недорого	Стоят дорого
Разброс стоимости этих квартир не очень большой	Разброс стоимости этих квартир очень большой

В выборку могут попасть объекты разного «размера» (например, площадь квартир, численность работников, население страны/региона,...), то есть основания подозревать гетероскедастичность

Как проверить?

Графический способ обнаружения гетероскедастичности, к сожалению, имеет ограниченное применение.



Как проверить?

Формальные статистические тесты

–Тест Уайта (Whitetest)

–Тест Голдфельда-Квандта (Goldfeld-Quandttest)

–ТестБреуш-Пагана (Breusch-Pagan test)

–Тест ранговой корреляции Спирмена (Spearman test)

–Тест Парка (The Park test)

–Тест Глейзера (Glejser test)

H_0 : гомоскедастичность остатков

H_1 : гетероскедастичность остатков

Если $|K_{\text{выч}}| < K_{\text{крит}}$, то нет оснований для отклонения H_0 для двусторонней альтернативы - гомоскедастичность остатков

Или

Если $p - \text{value} < \alpha$, то нулевую гипотезу H_0 следует отвергнуть

Что делать с гетероскедастичностью?

Избавляться!!!

Или от самой гетероскедастичности (взвешенный МНК?)

Или от ее последствий (Робастные стандартные ошибки)

1) **Взвешенный МНК** позволяет получить более **эффективные** оценки, но только при условии, что мы **верно** определили **вид/форму гетероскедастичности**, что большая **редкость**.

2) В прикладных исследованиях **чаще** используют **робастные стандартные ошибки**. Они **не устраняют гетероскедастичность**, но позволяют устранить ее негативное последствие в виде недооценок стандартных ошибок коэффициентов.

3) Как только есть **теоретические основания** утверждать о наличии **гетероскедастичности**, то следует использовать **робастные стандартные ошибки** (даже до проведения формальных тестов). Даже если в модели **нет гетероскедастичности**, то **робастные стандартные ошибки** будут давать **состоятельные** результаты.

4. Отсутствие автокорреляции ошибок

Если данное условие не выполняется, то говорят о том, что случайный член подвержен ***автокорреляции*** (***autocorrelation, serialcorrelation***).

В этом случае коэффициенты регрессии, получаемые по МНК, оказываются *неэффективными*, хотя и *несмещенными*, а их стандартные ошибки рассчитываются некорректно (занижаются).

Автокорреляция в регрессионном анализе обычно встречается при использовании данных временного типа.

Автокорреляция влечет за собой некорректные результаты.

Стандартные ошибки получаются несостоятельными, и мы не можем построить корректные доверительные интервалы и проверять гипотезы классическими способами.

Как проверить?

Проверить автокорреляцию можно с помощью теста Дарбина-Уотсона.


Выдвигается нулевая гипотеза об отсутствии автокорреляции первого порядка, т.е. $H_0: \rho = 0$.

В качестве альтернативной гипотезы может выступать либо $H_1: \rho \neq 0$ (есть автокорреляция)

Для проверки нулевой гипотезы используют статистику Дарбина – Уотсона:

$$DW = \frac{\sum_{i=2}^n (e_i - e_{i-1})^2}{\sum_{i=1}^n e_i^2}.$$

Если автокорреляция остатков *отсутствует*, то $DW \approx 2$.



Проверка гипотезы осуществляется с помощью табл. А8, содержащей критические значения критерия Дарбина – Уотсона: $d_U = d_U(\alpha, k, n)$ и $d_L = d_L(\alpha, k, n)$, определяемые по значениям входных параметров α, k, n .

Гипотеза об отсутствии автокорреляции первого порядка принимается, если выполняется неравенство $4 - d_U > DW_{выч} > d_U$; гипотеза отклоняется в пользу альтернативной, если $DW_{выч} > 4 - d_L$ или $DW_{выч} < d_L$.

5. Отсутствие полной (совершенной) мультиколлинеарности

Мультиколлинеарность – линейная взаимосвязь двух или нескольких объясняющих переменных

Например, может возникать при использовании признаков естественной взаимосвязью: стаж работы и возраст (как правило, чем больше возраст – тем больше стаж и наоборот), количество детских садов и количество школ в районе (обычно детские сады бывают при школе, так что эти количества пропорционально взаимосвязаны) или баллы за экзамены IELTS и TOEFL (так как они экзамены проверяют примерно одни и те же знания и навыки).

Совершенная мультиколлинеарность

Если объясняющие переменные связаны строгой функциональной зависимостью, это не позволяет однозначно определить коэффициенты регрессии и разделить вклады объясняющих переменных в их влиянии на зависимую переменную Y

$$X_1 = 1 + 3X_2$$

Несовершенная мультиколлинеарность

Сильная корреляционная зависимость между объясняющими переменными, характеризуется высоким коэффициентом корреляции между соответствующими объясняющими переменными

Последствия мультиколлинеарности

- ✓ Ухудшается точность выводов
- ✓ Уменьшаются t -статистики коэффициентов, что может привести к неоправданному выводу о существенности влияния соответствующей объясняющей переменной на зависимую переменную
- ✓ Оценки коэффициентов по МНК и их стандартные ошибки становятся очень чувствительными к малейшим изменениям данных, т. е. они становятся неустойчивыми.
- ✓ Затрудняется определение вклада каждой из объясняющих переменных в объясняемую уравнением регрессии дисперсию зависимой переменной
- ✓ Возможно получение неверного знака у коэффициента регрессии.

Последствием мультиколлинеарности является расширение доверительных интервалов для коэффициентов, и модель получается очень неустойчивой и меняющейся от добавления даже 1–2 новых наблюдений. Поэтому нужно отбирать для модели только те предикторы, между которыми нет линейной связи.

Как проверить?

1. Коэффициент детерминации R^2 достаточно высок, но некоторые из коэффициентов регрессии статистически незначимы, т.е. они имеют низкие t -статистики
2. **Парная корреляция** между малозначимыми объясняющими переменными достаточно высока. Однако данный признак будет надежным лишь в случае двух объясняющих переменных. При большем их количестве целесообразнее использование частных коэффициентов корреляции
3. **Высокие частные коэффициенты корреляции**. Частные коэффициенты корреляции определяют силу линейной зависимости между двумя переменными без учета влияния на них других переменных

Как проверить?

4. Сильная вспомогательная (дополнительная) регрессия.

Строятся уравнения регрессии каждой из объясняющих переменных X_j , $j=1, \dots, m$ на оставшиеся объясняющие переменные вспомогательной регрессии $X_j = \alpha_2 X_2 + \alpha_3 X_3 + \dots + \alpha_k X_k + c_0 + \epsilon$. Вычисляются соответствующие коэффициенты детерминации R_j^2 и рассчитывается

$$VIF_j = \frac{1}{1 - R_j^2}$$

Значение 1 указывает на отсутствие мультиколлинеарности в модели

Значение от 1 до 10 указывает на умеренную мультиколлинеарность

Значение больше 10 указывает на потенциально сильную мультиколлинеарность

Что делать мультиколлинеарностью?

Прежде чем указать основные методы устранения мультиколлинеарности, отметим, что в ряде случаев мультиколлинеарность не является таким уж серьезным злом, чтобы прилагать серьезные усилия по ее выявлению и устранению. Ответ на этот вопрос в основном зависит от целей исследования.

Если основная задача модели – прогноз будущих значений зависимой переменной, то наличие мультиколлинеарности зачастую не сказывается на прогнозных качествах модели.

Методы устранения мультиколлинеарности

Исключение переменной(-ых) из модели

Получение дополнительных данных или новой выборки

Изменение спецификации модели


Преобразование переменных

6. Нормальность распределения ошибок


Распределение ошибок (остатков) модели должно быть нормальным.

Проверить это можно визуально с помощью гистограммы, графика ***q-q plot*** или спомощью специальных статистических тестов (тесты Шапиро-Уилка,Лиллиефорса, Жарка-Бера). (прошлая лекция)

Histogram of mtcars\$qsec



Normal Q-Q Plot



ВАЖНО!!!

Уравнение регрессии обычно используют для того, чтобы прогнозировать какие-то значения.

- То есть с помощью уравнения можно по значениям X (независимой переменной) предсказать значения Y (зависимой переменной).
- Важно помнить несколько особенностей регрессии.
- 1. Предсказания всегда неидеальны, и в них будет какая-то ошибка – когда-то меньшая, когда-то большая. Величина ошибки связана с силой корреляционной связи между двумя переменными (чем коэффициент корреляции ближе к единице по модулю, тем меньше ошибка).
- 2. Значения, для которых делаются предсказания, должны быть из того же диапазона, что и значения, для которых получено уравнение регрессии.
- Если построили уравнение регрессии для предсказания цены на квартиру, используя данные о квартирах в ценовом диапазоне от 6 до 10 миллионов, то совершенно не обязательно наша модель будет подходить для предсказания цены квартиры из диапазона 40–50 млн.

Линейные регрессионные модели с фиктивными переменными

Фиктивная переменная (манекен, DUMMY) – вспомогательная переменная, используемая либо вместо реальной содержательной неколичественной переменной, либо для описания каких-либо содержательных обстоятельств. Чаще всего применяется в одной из трех ситуаций.

Ситуация 1 (применение фиктивных переменных к описанию влияния качественных переменных). Требуется построить модель, описывающую зависимость размера заработной платы Y работника от стажа его работы X_1 , возраста работника X_2 , а также наличия высшего образования X_3 . В данном случае переменная X_3 является качественной. Она может быть учтена в модели опосредованно через фиктивную переменную D , определяемую следующим образом:

$$D = \begin{cases} 0, & \text{если работник не имеет высшего образования,} \\ 1, & \text{если работник имеет высшее образование.} \end{cases}$$

Если предположить, что зависимость носит линейный характер, то искомая модель будет определяться следующим выражением:

$$Y = b_0 + b_1 X_1 + b_2 X_2 + b_3 D + \varepsilon .$$

Важно отметить, что коэффициент при фиктивной переменной в подобных моделях, как правило, имеет определенную содержательную интерпретацию. В данном случае коэффициент b_3 показывает, насколько работник с высшим образованием получает в среднем «больше» работника без высшего образования при прочих равных обстоятельствах.

Проверка гипотезы вида $b_3 = 0$ в рамках этой модели равноценна проверке предположения о том, что наличие высшего образования не оказывает существенного влияния на уровень оплаты труда.

Ситуация 2 (применение фиктивных переменных к описанию обстоятельств, носящих сезонный или периодический характер). Требуется построить модель, описывающую зависимость объема потребляемого продукта Y от времени года. При этом предполагается, что никакие другие обстоятельства не сказываются на величине потребления. Поскольку известны 4 времени года (зима, весна, лето, осень), следует применить 4 фиктивные переменные:

$$D_1 = \begin{cases} 1, & \text{если определяется величина потребления зимой,} \\ 0 - & \text{в остальных случаях.} \end{cases}$$

$$D_2 = \begin{cases} 1, & \text{если определяется величина потребления весной,} \\ 0 - & \text{в остальных случаях,} \end{cases}$$

$$D_3 = \begin{cases} 1, & \text{если определяется величина потребления летом,} \\ 0 - & \text{в остальных случаях,} \end{cases}$$

$$D_4 = \begin{cases} 1, & \text{если определяется величина потребления осенью,} \\ 0 - & \text{в остальных случаях.} \end{cases}$$

Одна из этих переменных линейно выражается через другие, так как верно следующее тождество: $D_1 + D_2 + D_3 + D_4 = 1$. Это свойство фиктивных переменных называется «**проклятием фиктивных переменных**».

Поэтому искомая зависимость может быть описана с помощью любых трех из них. Выбирая первые 3 фиктивные переменные, приходим к модели

$$Y = b_0 + b_1 D_1 + b_2 D_2 + b_3 D_3 + \varepsilon.$$

Поскольку функция $Y_D = b_0 + b_1 D_1 + b_2 D_2 + b_3 D_3$ в данном случае показывает средний объем потребления в любое время года, ее коэффициенты имеют определенный содержательный смысл: значение b_0 равно среднему объему потребления при $D_1 = D_2 = D_3 = 0$, то есть осенью; значение $b_0 + b_1$ равно среднему объему потребления при $D_1 = 1, D_2 = D_3 = 0$, т.е. зимой, поэтому коэффициент b_1 показывает, насколько величина потребления зимой «больше», чем осенью. Аналогичную интерпретацию имеют коэффициенты b_2 и b_3 . Таким образом, каждый из коэффициентов b_1, b_2, b_3 показывает средние сезонные отклонения в объеме потребления. Проверка гипотезы вида $b_i = 0, i = 1, 2, 3$ в этом случае состоит в проверке предположения о несущественном различии в объеме потребления осенью и в i -е время года.

Ситуация 3 (применение фиктивных переменных к построению кусочно-линейных регрессионных моделей). Пусть x_t – размер основных фондов некоторого предприятия в период t , а y_t – объем продукции, выпущенной за этот же период. Предполагаем, что в любой момент времени зависимость между

этими показателями является линейной, однако в известный момент времени t_0 происходит изменение уравнения регрессии. На формальном уровне такая зависимость может быть описана следующим образом:

$$y_t = b_0 + b_1 x_t + b_2 (x_t - x_{t_0}) D_t + \varepsilon_t, \quad t = 1, 2, \dots, n.$$

В данном случае $D_t = 0$ при $t \leq t_0$ и $D_t = 1$ при $t > t_0$. При этом линейная функция регрессии имеет коэффициент наклона b_1 при $t \leq t_0$ и $b_1 + b_2$ при $t > t_0$. Проверка гипотезы $b_2 = 0$ в этом случае равносильна проверке предположения о том, что функция регрессии не изменяется с течением времени, т.е. *в модели отсутствуют структурные изменения*.

Фиктивные переменные обычно принимают только одно из двух значений –0 или 1, это позволяет записать все основные статистики, используемые при проведении статистического анализа линейной регрессионной модели с фиктивной переменной, в более простой форме. Убедимся в этом, рассмотрев следующий пример.