

Дисциплина «Анализ данных»

3-4 модуль 2025-26 уч.г

Радионова Марина Владимировна, к.ф.-м.н., доцент, кафедра информационных технологий в бизнесе НИУ ВШЭ-Пермь

e-mail: m.radionova812@gmail.com

Схема: 24 ч лекций, 22 ч семинаров, 16 лаб

ИТОГО = 0,4 Экзамен + 0,2 ДЗ + 0,1 Аудиторная работа + 0,3 КР

Литература:

1. Кобзарь, А.И. Прикладная математическая статистика. — М.: Физматлит, 2006.
2. Лагутин, М.Б. Наглядная математическая статистика. — М.: П-центр, 2003.
3. Миркин, Б. Г. Введение в анализ данных : учебник и практикум / Б. Г. Миркин. — Москва : Издательство Юрайт, 2016. — 174 с.
4. Анализ данных : учебник для академического бакалавриата / В. С. Мхитарян [и др.] ; под редакцией В. С. Мхитаряна. — Москва : Издательство Юрайт, 2019. — 490 с.

Что это такое?

Методами статистической обработки (методами прикладного анализа данных) результатов эксперимента называются математические приемы, формулы, способы количественных расчетов, с помощью которых показатели, получаемые в ходе эксперимента, можно обобщать, приводить в систему, выявляя скрытые в них закономерности. Речь идет о таких закономерностях статистического характера, которые существуют между изучаемыми в эксперименте переменными величинами.

Современная тенденция: широкое использование анализа статистических данных в экономическое науке в бизнесе/финансах, в социальных науках, в политических науках

Некоторые причины:

Доступность статистических данных, в т.ч. открытых

Доступность вычислительных мощностей (РС, серверы/облака, суперкомпьютеры)

Современный вероятностно-статистический аппарат

Какие преимущества даёт анализ статистических данных:

Получение новых знаний

Проверка теорий на “согласованность с реальностью”

Поддержка принятия решений (Data Driven Decision)

Количественные оценки зависимостей между факторами

Тестирование гипотез

Практические выводы (прогнозирование, оценка последствий от принятия решений, etc)

Дополнительное конкурентное преимущество

Проблемы прикладного анализа данных

Проблемы прикладного анализа данных

Существенный недостаток информации (непреодолимый).

Невозможно учесть всё!

Например, многие факторы ненаблюдаемы.

Пример (Функция спроса) *Линейная функция спроса*

$$Q = \beta_0 + \beta_1 P$$

не подходит для описания реальной зависимости, т.к. спрос не определяется только ценой!

Вопрос: Как работать при неопределённости/недостатке информации?

Проблемы прикладного анализа данных

Ответ: Стандартно используется аппарат теории вероятностей и мат. статистики.

Пример (Функция спроса) Более реалистична модель спроса


$$Q = \beta_0 + \beta_1 P + \varepsilon,$$

где ε – ненаблюдаемая случайная величина, описывающая влияние невключённых (например, ненаблюдаемых) факторов.

Случайность




Случайность




Случайность



Случайность



Изучение случайности



Вероятность события — доля испытаний, завершившихся наступлением события, в бесконечном эксперименте.

Изучение случайности



Изучение случайности



Изучение случайности



Закон больших чисел: на больших выборках частота события хорошо приближает его вероятность.

Основные статистические модели/методы:

- ✓ Базовые распределения случайных величин (нормальное, Биномиальное ... etc)
- ✓ Первичный анализ данных и визуализация
- ✓ Корреляционный анализ
- ✓ Метод главных компонент
- ✓ Кластерный анализ и задача классификации
- ✓ Методы регрессионного анализа (линейная регрессия, модели бинарного выбора etc)
- ✓ Методы анализа временных рядов
- ✓ ML/AI (нейронные сети, глубокое обучение etc)

Случайные величины

Случайная величина (СВ) – это величина, которая принимает некоторые значения случайным образом (численная характеристика случайного события).

Примеры:

рост жителей Пермского края,
температура по палате,
размер заработной платы

- СВ бывает дискретные и непрерывные

Дискретные случайные величины

- *Дискретная СВ* – принимает конечное (счетное) число значений.

Целое число.

- Примеры:

число детей в семье,
количество заболевших,
число студентов, не сдавших зачет,
количество студентов на лекции...

Непрерывные случайные величины

- **Непрерывная СВ** – случайная величина, значения которой сплошь покрывают некоторый интервал (a, b) или всю числовую ось $(-\infty, +\infty)$.

Нецелое число.

Пример:

время ожидания автобуса на остановке,
температура воздуха на улице,
рост жителей Пермского края,
уровень доходов населения...

Закон распределения СВ

СВ нельзя предсказать, однако можно судить о ее поведении, зная ее распределение.

СВ принимает то или иное значение в соответствии со своим законом распределения.

Распределение (закон распределения) СВ – это закон (формула), определяющий область значений случайной величины и соответствующие вероятности появления этих значений.

Распределение позволяет ответить на вопрос, с какой вероятностью случайная величина принимает то или иное значение.


Распределение дискретной СВ

Закон распределения дискретной СВ (ДСВ) может быть задан *рядом распределения* и *функцией распределения*.

Ряд распределения:

X	10	20	50
$P(X)$	0,3	0,6	0,1

График ряда распределения – полигон (многоугольник) распределения вероятностей:




Распределение непрерывной СВ

Закон распределения непрерывной СВ может быть задан *функцией распределения* и *плотностью вероятности*.

1. Функция распределения – показывает, с какой вероятностью случайная величина X принимает значение меньшее, чем заданное x :

$$F(x) = P(X < x)$$

Пример графика функции распределения непрерывной СВ:




Распределение непрерывной СВ

2. Плотность вероятности непрерывной СВ


грубо можно сказать, что она характеризует вероятность, с которой случайная величина X_i принимает значение x .

Пример графика плотности вероятности непрерывной СВ:



Распределение непрерывной СВ

Однако значение плотности вероятности, в отличие от значения функции распределения, – это не вероятность.



Числовые характеристики СВ

Условно числовые характеристики случайной величины можно разделить на 3 группы, характеризующие ее распределение:


1. Характеристики **положения**, меры центральной тенденции (математическое ожидание, мода, медиана). Некоторым образом характеризуют среднее, ожидаемое значение случайной величины.
2. Характеристики **рассеяния**, меры изменчивости (размах вариации, дисперсия, стандартное отклонение, коэффициент вариации). Характеризуют разброс значений случайной величины вокруг среднего (математического ожидания).
3. Характеристики **формы** распределения (асимметрия, эксцесс). Характеризуют геометрическую форму распределения.

Характеристики положения

Математическое ожидание – это значение случайной величины, которое она принимает в среднем. Обозначается $M(X)$ или $M[X]$.

Мода – значение случайной величины, которое она принимает с наибольшей вероятностью (самое часто встречающееся значение). Обозначается M_o .


Если таких значений несколько, то распределение называется полимодальным (многомодальным).



Характеристики положения

Медиана – это значение СВ, делящее множество значений СВ пополам, т.е. половина элементов меньше (не больше) медианы, а половина – больше (не меньше).

Обозначается **Me**.



Характеристики рассеяния (разброса)


Размах вариации – разность между максимальным и минимальным значением случайной величины. Обозначается **R** .

Дисперсия – величина, характеризующая разброс значений случайной величины около математического ожидания $M(X)$. Обозначается **$D(X)$** или **$D[X]$** или **σ^2** .

Стандартное (среднеквадратическое) отклонение – квадратный корень из дисперсии. Характеризует среднее абсолютное отклонение значений СВ от ее мат. ожидания. Обозначается **σ** .

Характеристики рассеяния (разброса)

Представим, что мы делаем множество выстрелов по мишени. Примерная иллюстрация на понимание:



Характеристики рассеяния (разброса)

Коэффициент вариации – величина, характеризующая среднее относительное отклонение значений СВ от ее мат. ожидания. Обозначается **V** , измеряется в процентах.

Пример:



Характеристики рассеяния в экономических задачах часто используют как **меру риска** инвестиционных вложений. Чем сильнее может отклоняться ожидаемая доходность от своего среднего значения, тем более рискован такой проект.

Например, в среднем ожидаем доходность 20%, а $V = 3\%$. Значит, мы получим доходность от 17 до 23%. А если $V = 50\%$? Можно как разбогатеть, так и разориться, проект рискованный.

Характеристики формы распределения

Как следует из названия этой группы характеристик, они описывают **геометрическую форму** распределения случайной величины.


В общем случае речь идет о графике функции плотности вероятности



Характеристики формы распределения


Коэффициент асимметрии (асимметрия) — характеризует симметричность формы распределения.

Для симметричной формы распределения коэффициент асимметрии равен нулю. Если $As > 0$, то данные имеют положительную асимметрию (правостороннюю), а если $As < 0$ — отрицательную (левостороннюю).



Правосторонняя

и




Левосторонняя асимметрия

Характеристики формы распределения

Коэффициент эксцесса (эксцесс) – характеризует островершинность формы распределения (так называемой крутости распределения).


Если $E_x > 0$, распределение островершинное,
если $E_x < 0$ – плосковершинное. Чем больше $|E_x|$, тем сильнее отклонение высоты распределения от нормального ($E_x = 0$).



Квантили распределения

Квантиль (односторонний) уровня $p \in [0; 1]$ (обозначается x_p) – это такое значение x_p , меньше которого окажется значение случайной величины X с вероятностью p .

Например, квантиль уровня 0,75: $F(x_{0,75}) = P(X < x_{0,75}) = 0,75$



Медиана, квартили, процентили – это все частные случаи квантиля.

Медиана = второй квартиль:

$$Me = Q_2 = x_{0,5}$$

Первый и третий квартили:

$$Q_1 = x_{0,25}$$

$$Q_3 = x_{0,75}$$

Стандартные законы распределения СВ

Однако существуют **стандартные** законы распределения, которые часто встречаются.

Случайные величины, распределенные по таким типовым законам, принимают значения, вероятности которых рассчитываются **по определенным формулам этих законов**.

К ним относятся: равномерное, показательное (экспоненциальное), нормальное распределения, а также распределения Стьюдента, Фишера, хи-квадрат.

Закон распределения непрерывной случайной величины X задается 2-мя способами: **функцией распределения и плотностью вероятности**.

В случае стандартного закона распределения **формулы этих функций заранее известны**. Также известны числовые характеристики: **формулы $M(X)$ и $D(X)$** .



Равномерное распределение $X \sim R(a, b)$

Имеет 2 параметра: a (минимальное значение X) и b (максимальное значение X).

Функция распределения и функция плотности:

$$F(x) = \begin{cases} 0 & \text{при } x \leq a \\ \frac{x-a}{b-a} & \text{при } a < x \leq b \\ 1 & \text{при } x > b \end{cases} \quad f(x) = \begin{cases} 0 & \text{при } x < a \\ \frac{1}{b-a} & \text{при } a \leq x \leq b \\ 0 & \text{при } x > b \end{cases}$$

Графики функций плотности и распределения:



Как видно, равномерно распределенная СВ принимает значения из интервала $(a; b)$ с одинаковой вероятностью. Следовательно, у нее **нет моды**.

Числовые характеристики: $M(X) = \frac{a+b}{2}$ $D(X) = \frac{(b-a)^2}{12}$

Нормальное (гауссово) распределение $X \sim N(a, \sigma^2)$

Имеет 2 параметра: $a = M(X)$, $\sigma^2 = D(X)$ (иногда σ вместо σ^2)

Функция распределения

$$F(x) = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{(x-a)^2}{2\sigma^2}} dx = \Phi\left(\frac{x-a}{\sigma}\right)$$


и функция плотности:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}}$$

Нормальное распределение играет важнейшую роль во многих областях знаний. Случайная величина подчиняется нормальному закону распределения, когда она подвержена влиянию большого числа случайных факторов, что является типичной ситуацией в анализе данных. Поэтому нормальное распределение служит хорошей моделью для многих реальных процессов



Нормальное (гауссово) распределение $X \sim N(\alpha, \sigma^2)$

Графики функции плотности распределения (*кривая Гаусса или нормальная кривая*)



Данная функция получила название по фамилии некоронованного короля математики, немецкого ученого **Карла Гаусса** и график её плотности можно было найти на денежной единице номиналом в 10 дойчмарок до 1 января 2012 г.

Нормальное (гауссово) распределение $X \sim N(a, \sigma^2)$




Особенности нормального распределения: $Mo = Me = M(X) = a$

Оно симметрично ($As = 0$) и обладает «нормальной» остротой пика ($Ex = 0$).

Числовые характеристики: $M(X) = a$ $D(X) = \sigma^2$

Стандартное нормальное распределение имеет параметры $a = 0$, $\sigma^2 = 1$, обозначается $N(0, 1)$.

Правило 3-х сигм



$M(X) = a$ – математическое ожидание (среднее значение) X
 σ (сигма) – стандартное отклонение (отклонение от среднего) X

Чем ближе значение СВ к среднему (математическому ожиданию), тем с большей вероятностью оно встречается.

Правило 3-х сигм: 99,7% всех значений нормально распределенной случайной величины отклоняются от ее математического ожидания не более чем на 3 стандартных отклонения

Другие важные законы распределения




$X \sim St(v)$ – распределение Стьюдента
с v степенями свободы

$X \sim F(v_1, v_2)$ – распределение Фишера
с v_1, v_2 степенями свободы

$X \sim \chi^2(v)$ – распределение хи-квадрат
с v степенями свободы

Квантили этих распределений используются
при построении доверительных интервалов
и проверке статистических гипотез.

Их значения приведены в статистических таблицах.



Понятие числа степеней свободы

В статистике **число степеней свободы** – это количество значений, используемых при расчете статистической характеристики, которые могут свободно изменяться. Представляет собой целое неотрицательное число.

Оценки статистических характеристик могут производиться на разных объемах данных. Количество независимых элементов данных, которые используются при оценке характеристики, называют числом степеней свободы.

Наиболее часто данное понятие используется при описании линейных моделей (линейная регрессия, дисперсионный анализ), где рассматриваются случайные векторы наблюдений, расположенные в многомерном пространстве. Тогда число степеней свободы равно размерности пространства.

Кроме этого, число степеней свободы является параметром некоторых важных статистических распределений – хи-квадрат, Стьюдента, Фишера.

Статистический анализ данных

В теории показатель (случайная величина) должен вести себя именно так, как гласит закон его распределения.

Другими словами, если взять все-все-все возможные значения X , они будут распределены по этому закону.

На практике теоретические законы распределения тех или иных случайных величин **известны нечасто**.

Например, X – рост жителя России. Каков закон его распределения? Так сразу не ответить. Чтобы составить закон, надо измерить рост у всех 146 млн россиян. Как правило, возможности это сделать нет.

Основные понятия

Два базовых понятия:

Генеральная совокупность (population) – это множество всех возможных значений признака, которое можно было бы получить в данном исследовании, т.е. которое должно быть наблюдаемо.

Выборочная совокупность или **Выборка** (sample): ограниченная информация из генеральной совокупности – это часть генеральной совокупности, состоящая из некоторого числа значений признака, случайным образом отобранная из соответствующей генеральной совокупности, т.е. элементы которой реально наблюдаемы.

Основные понятия

Пример:

Генеральная совокупность: все жители России

Признак (случайная величина): рост всех жителей России.

Выборочная совокупность или **Выборка:** рост 100 жителей России; кто-то бегал по улицам городов с рулеткой и измерял рост прохожих (если удавалось догнать).

ВАЖНО!!! В статистических исследованиях различные показатели изучаются по выборкам. На основании анализа выборки делаются выводы обо всей генеральной совокупности.

Почему это работает? Благодаря **закону больших чисел**.

Основные понятия

Закон больших чисел — это принцип в теории вероятностей, согласно которому при увеличении числа экспериментов (объема выборки) численные характеристики показателя, полученные по выборке, т.е. его оценки, приближаются к своим теоретическим значениям.

Чем **больше** выборка — тем **точнее** оценка численной характеристики случайной величины.

Например:

относительная частота того или иного значения X_i в выборке стремится к вероятности этого значения.

Пример: подкидывание монеты

Многие учёные проводили эксперимент.
При многократном бросании монеты
подсчитывалось число выпадений орла.



Ученый	Количество подбрасываний	Выпадений ОРЛА	Частота
Бюффон	4040	2048	0,507
Де Морган	4092	2048	0,5005
Джеворнс	20480	10379	0,5068
Романоский	80640	39699	0,4923
Пирсон К.	24000	12012	0,5005
Феллер	10000	4979	0,4979

Вывод: выпадение ОРЛА стремиться к $1/2$

Основные понятия

Выборка может быть *повторной*, при которой отобранный объект (перед отбором следующего) возвращается в генеральную совокупность, и *бесповторной*, при которой отобранный объект не возвращается в генеральную совокупность.

Число N — объем генеральной совокупности

число n — объем выборки

Выборка $\mathbf{X} = (X_1, X_2, \dots, X_n)$, наблюдаемые значения X_i называют *вариантами*.

Репрезентативность выборки

Репрезентативность выборки – это соответствие характеристик выборки характеристикам генеральной совокупности.



Качество данных

Качество данных (Data quality) – это характеристика данных, отражающая степень их пригодности к решению определенной задачи.

- Оценка качества данных и действия по его повышению являются необходимым этапом любого аналитического проекта, поскольку аналитические алгоритмы или не смогут работать с некачественными данными, или будут давать некорректные результаты.

- Приведение исходных «сырых» данных в соответствие с требуемыми критериями качества является важнейшей задачей Data Mining и образует направление, называемое **предобработкой**.

GIGO (Garbage In, Garbage Out) –
"Мусор на входе, мусор на выходе"

«80% времени я трачу на очистку данных.

Качественные данные всегда выигрывают у качественных моделей.»


Томсон Нгуен, data-специалист



Качество данных

Критерии качества данных:

- **полнота** (нарушение: в данных о клиенте не указано его имя)
- **достоверность**
- **точность** (нарушение: неактуальный номер телефона клиента)
- **согласованность** (нарушение: в двух используемых базах имена клиента разные)
- **доступность** (аналитику должны быть доступны как данные, так и инструменты их обработки)
- **своевременность** (данные могут быстро устаревать).



Качество данных

Основные проблемы, вызывающих снижение качества данных:

- пропущенные значения;
- дубликаты;
- противоречия;
- аномальные значения (выбросы);
- шум (искажения в данных, обусловленные случайными факторами);
- отсутствие полноты данных;
- нарушения целостности данных;
- некорректные форматы и представления данных;
- фиктивные значения;
- ошибки ввода данных;
- нарушения структуры.
- Некоторые из этих проблем являются критическими – они блокируют работу аналитических моделей и алгоритмов (например, пропущенные значения и нарушения структуры).
- Другие (например, дубликаты, противоречия, шумы) не нарушают работу алгоритмов, но порождают некорректные результаты анализа.

Качество данных

Очистка данных (*Data cleansing* или *Data cleaning* или *Scrubbing*) — процесс выявления и исправления ошибок, несоответствий данных с целью улучшения их качества, иногда классифицируется как составная часть любого анализа данных.



Пропуски и выбросы в данных

Пропуски или *пропущенные значения (missing values)* – это отсутствующее наблюдение.

Аномальные значения в данных или *выбросы (Outliers)* – это таких значения, которые значительно отличаются от большинства других значений выборки.

Отличие выбросов от пропусков:

Выброс – это часто реально существующий объект, но обладающий аномальными свойствами, он сильно отличается от других объектов выборки.

Пропуск или некорректное значение – это величина, которая появилась в результате человеческого фактора (халатность, ошибка ввода).

Некоторые методы устранения пропусков

Простейшие:

1. Удалить запись об объекте (т.е. строку).
2. Удалить столбец, если в нём очень много пропусков.

Но в результате можно получить очень маленькую таблицу.

Более продвинутые:

- ✓ Заменить значение в ячейке на среднее значение (медиану, моду...) из значений столбца.
- ✓ Взять среднее двух соседних элементов.



Методы анализа выбросов будут дальше

Статистический анализ данных

Статистические данные (информация) - совокупность характеристик массовых явлений и процессов, полученных в результате статистического наблюдения.

Признак, который регистрируется для каждого из объектов, называют **переменной**.

Переменная – обозначение какого-либо показателя.

Статистические данные являются основой для выявления и обоснования эмпирических закономерностей.

Статистические методы и модели зависят от вида статистических данных.

Типы статистических данных:

Перекрестные данные

Временные ряды

Панельные данные

Перекрестные данные (*cross-section data*) - это данные по какому либо экономическому показателю, полученные для разных однотипных объектов (фирм, регионов). При этом все данные относятся либо к одному и тому же моменту времени, либо их временная принадлежность несущественна.

Пример: бюджетное обследование населения в определенный момент времени.

Типы статистических данных:

Временные ряды (*time series*) – это данные, характеризующие один и тот же объект, но в различные моменты времени.

Пример: данные о динамике уровня инфляции за определенный период.

Панельные данные (*panel data*) – перекрестные данные + временные ряды

Пример: данные о доходах разных групп населения с 2000 по 2020 год

Классификация статистических данных

Количественные данные - эти данные регистрируются с помощью чисел, имеющих содержательный смысл.

С количественными данными можно выполнять все обычные операции над числами, такие как вычисление среднего и оценку изменчивости.

Примеры: рост, вес, уровень доходов, уровень инфляции, количество студентов на лекции, температура воздуха...

Классификация статистических данных

Качественные данные — это данные, характеризующие определенное качество, свойство, которым обладает объект.

Примерами качественных данных являются должность, которую занимает сотрудник на предприятии, национальность и т. п.

Номинальные (категориальные): признак не имеет числовой природы; как правило, число его возможных значений конечно.

Пример: марка смартфона, цвет глаз.

Классификация статистических данных

Бинарный (альтернативный) признак – это номинальный признак с двумя возможными (противоположными) значениями.

Пример: пол человека, категория кредита (с просрочками платежа/без).

Для учета таких данных в виде количественно измеримых величин им присваивают числовые значения (кодируют). Под кодирование будем понимать сопоставление значению переменной некоторого числа, называемого кодом, например, пол человека можно закодировать числами 0 и 1.

Порядковые (ранговые): значения признака упорядочены, расположены на некоторой шкале.

Пример: уровень образования, категория специалиста 2-я, 1-я, высшая).

Группировка данных и визуализация

Количественные данные

Число N — объем генеральной совокупности

число n — объем выборки

Выборка $\mathbf{X} = (X_1, X_2, \dots, X_n)$, наблюдаемые значения X_i называют *вариантами*.

Способы представления количественных данных

Пример: имеются данные о баллах, полученных студентами за контрольную работу:

10, 50, 10, 20, 10, 20, 20, 10, 20, 20, 10, 20, 20, 20.

1) Вариационный ряд – это упорядоченная по возрастанию выборка и обозначается $X_{(1)}, X_{(2)}, \dots, X_{(n)}$, где $X_{(i)} < X_{(i+1)}$, а элементы вариационного ряда $X_{(i)}$ называются **порядковыми статистиками**.

10, 10, 10, 10, 10, 20, 20, 20, 20, 20, 20, 20, 20, 20, 50

Способы представления количественных данных

2) Дискретный ряд – для каждого X_i указывается его относительная частота (частость или оценка вероятности) $p_i^* = \frac{n_i}{n}$, где n_i – количество значений X_i в выборке, n – объем выборки.

X_i	10	20	50
n_i	5	8	1
p_i^*	5 / 14	8 / 14	1 / 14

Сумма относительных частот равна **единице**:


$$\sum_{i=1}^k p_i^* = 1,$$

где k – количество уникальных значений X в выборке.

Способы представления количественных данных

По дискретному ряду можно построить **полигон (многоугольник) частот** (просто частот n_i или относительных частот p_i^* , надо внимательно читать задание).

Это график, по оси X которого откладываются значения X_i , а по оси Y – частоты или относительные частоты.



Способы представления количественных данных

3) **Интервальный ряд** – диапазон значений X разбивается на интервалы, и для каждого интервала указывается его относительная частота.

Т.е. **отличие от дискретного ряда** в том, что там указывалась частота конкретного значения X_i , а тут – частота значений, входящих в тот или иной интервал.

n_i в данном случае – количество значений, попадающих в интервал.

Интервалы	[10; 20)	[20; 30)	[30; 40)	[40; 50]
n_i	5	8	0	1
p_i^*	0,36	0,57	0	0,07

Способы представления количественных данных

Построение интервального ряда:

1) Определяем количество интервалов по формуле Стэрджесса:

$$k = 1 + [3,32 \log_{10} n] \quad ([a] - \text{целая часть } a),$$

ширину интервала – по формуле

$$h = \frac{\max(X_i) - \min(X_i)}{k}$$

2) Далее строим интервальный ряд в виде **таблицы**.

Левая граница первого интервала = минимальный элемент выборки. Левые границы всегда включаются в интервал.

Правая граница последнего интервала = максимальный элемент. Она всегда включается в интервал. А все остальные правые границы – нет.


Правая граница интервала определяется как левая граница + h .

Интервалы	[10; 20)	[20; 30)	[30; 40)	[40; 50]
n_i	5	8	0	1
p_i^*	0,36	0,57	0	0,07

Способы представления количественных данных

По интервальному ряду можно построить **гистограмму** (столбчатую диаграмму).





По оси X откладываются границы интервалов значений X_i , а по оси Y – частоты или относительные частоты. Для каждого интервала строится столбик шириной h и высотой n_i или p_i^* .



Интервалы	[10; 20)	[20; 30)	[30; 40)	[40; 50]
n_i	5	8	0	1
p_i^*	0,36	0,57	0	0,07

Способы представления количественных данных


Поскольку **гистограмма** показывает частоту и, следовательно, визуализирует распределение переменной, столбцы обычно располагаются вплотную друг к другу без зазоров.



Способы представления данных временных рядов

Линейный график часто используется для визуализации временных рядов

Причины смерти в Италии, 1980–2016 гг.



Источник данных: OECD.stat [онлайновая база данных]. Paris: Organisation for Economic Co-operation and Development; 2020 (<https://stats.oecd.org/>, по состоянию на 5 февраля 2021 г.).

Способы представления качественных данных

Качественные данные обычно изображаются в виде секторной (круговой) или ленточной (линейчатой) диаграмм

Распределение причин смерти
в Нидерландах, 2016 г.



Распределение причин смерти
в Нидерландах, 2016 г.



Числовые характеристики выборки

Условно числовые характеристики выборки можно разделить на **3 группы**, характеризующие эмпирическое распределение выборки:

1. Характеристики **положения** (выборочное среднее, мода, медиана). Некоторым образом характеризуют среднее значение выборки.
2. Характеристики **рассеяния** (размах вариации, дисперсия, стандартное отклонение, коэффициент вариации). Характеризуют разброс значений выборки вокруг среднего.
3. Характеристики **формы распределения** (асимметрия, эксцесс). Характеризуют геометрическую форму распределения.

Характеристики положения

Выборочное среднее – это среднее арифметическое всех элементов выборки. Обозначается $\bar{X}$.

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \text{где } n \text{ – объем выборки}$$

Среднее арифметическое является наиболее важной характеристикой положения, поскольку при его определении используется вся имеющаяся информация о выборке.

Из определения среднего арифметического следует, что сумма отклонений выборочных значений признака от него равна нулю.

Характеристики положения

Мода – самое часто встречающееся значение в выборке, т.е. значение с наибольшей частотой. Обозначается M_o .

Если в выборке несколько таких значений, то распределение этой выборки называется полимодальным (многомодальным).




Рис. 1 Мода




Рис. 2. Полимодальное распределение

Характеристики положения

Медиана – это значение, делящее выборку пополам, т.е. половина элементов выборки меньше медианы, а половина – больше.

Для обозначения медианы принято использовать символы Me .

В случае несгруппированных данных для нахождения медианы необходимо ранжировать выборку, т. е. расположить данные в порядке их возрастания или убывания. Медианой будет являться значение признака, находящееся в середине ранжированного ряда.

Медиана находится по формуле

$$M_e = \begin{cases} X_{\left(\frac{n+1}{2}\right)}, & \text{если } n - \text{нечетное,} \\ \frac{X_{\left(\frac{n}{2}\right)} + X_{\left(\frac{n}{2}+1\right)}}{2}, & \text{если } n - \text{четное.} \end{cases}$$



Медиана

Например, медианная зарплата.

Пусть есть выборка из 1000 человек, из которых 999 чел. получает 20 тыс., а один получает миллиард.



Если взять всех и упорядочить по возрастанию, получится такой ряд

О среднем, медиане и моде на примере зарплат в Пермском крае:

<https://59.ru/text/job/2021/08/09/70038701/>

Об ограниченности статистик

Значения среднего арифметического, моды и медианы совпадают только для симметричных одномодальных распределений. Чем сильнее форма распределения отклоняется от симметричной, тем большее различие наблюдается между значениями характеристик положения.

Мода часто применяется в следующих случаях: в маркетинговых исследованиях, связанных с оценкой спроса и предложения на наиболее востребованные (модные) товары и т.п.

Медиана распределения чаще всего применяется в тех случаях, когда нужно учесть не только числовые значения данных, но и структурные особенности выборки.

Об ограниченности статистик (пример)

Пример. Определить среднюю цену квартиры в некотором районе г. Перми по имеющимся данным (тыс. руб.):

220, 320, 340, 410, 360, 1700, 365.

По имеющимся данным определить среднюю цену квартиры.

Решение. $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{7} (220 + 320 + 340 + 410 + 360 + 1700 + 365) = 530,71$
и медиану $M_e = X_{(4)} = 360$.

Полученное среднее арифметическое значение не будет являться наиболее типичным значением цены однокомнатной квартиры, т.к. большинство квартир (6 из 7) предлагаются по цене ниже 420 тыс.руб. Следовательно, в этом случае применение среднего арифметического для оценок и выводов приводит к ошибочным и недостоверным результатам. Так, потенциальный покупатель, желающий приобрести квартиру по цене, не превышающую 360 тыс. руб., при принятии решения на основе средней цены, скорее всего, откажется от покупки квартиры в данном районе. В то же время более 85% предложений удовлетворяют его требованиям.

Здесь целесообразно использовать медиану, которая равна 360 тыс. руб. В данном случае медиана будет правильнее в качестве показателя, характеризующего наиболее типичное значение из имеющихся данных

Характеристики рассеяния (разброса)

1. **Размах вариации** определяется как разность между максимальным и минимальным значением признака

$$R = X_{max} - X_{min}.$$

2. **Дисперсия** представляет собой средний квадрат отклонения значения случайной величины от ее среднего значения. Дисперсия есть характеристика рассеяния, разбросанности значений величины около ее среднего значения. Само слово «дисперсия» означает «рассеяние».

Выборочная дисперсия находится по формуле

$$S_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}.$$

Используется также другая формула для вычисления дисперсии: $S_X^2 = \overline{X^2} - (\bar{X})^2$, где $\overline{X^2} = \frac{1}{n} \sum_{i=1}^n X_i^2$.

Исправленная дисперсия (несмещенная оценка дисперсии) $S_0^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$.

Характеристики рассеяния (разброса)

3. **Стандартное отклонение** (или **средне квадратичное отклонение**) - положительный квадратный корень из дисперсии: $S_x = \sqrt{S_x^2}$.

Стандартное отклонение имеет те же единицы измерения, что и результаты измерения исследуемого признака, и, таким образом, оно характеризует степень отклонения признака от среднего арифметического. Иными словами, оно показывает, как расположена основная часть вариантов относительно среднего арифметического

Пример: очень часто можно встретить запись

$$\bar{X} \pm S_x$$

Характеристики рассеяния (разброса)

4. Коэффициент вариации равен отношению стандартного отклонения к

среднему арифметическому и выражен в процентах: $V = \frac{S_x}{\bar{X}} \cdot 100\%$

Из определения ясно, что по своему смыслу коэффициент вариации представляет собой относительную меру рассеяния признака.

Разброс результатов измерений:

небольшой ($V < 10\%$),

средний (11–20%),

большой ($V > 20\%$).


Коэффициент вариации используется для характеристики **однородности** полученных экспериментальных данных. Если $V < 33\%$, то совокупность считается однородной. Если $V \geq 33\%$, то **неоднородной**.

Характеристики формы распределения

Как следует из названия этой группы характеристик, они описывают **геометрическую форму** распределения.

Примерами визуализации распределения могут служить полигон частот и гистограмма.

Но удобнее рассматривать форму распределения на графике плотности вероятности непрерывной случайной величины.



Характеристики формы распределения


Коэффициент асимметрии (асимметрия) – характеризует симметричность формы распределения.

$$As^* = \frac{\mu_3}{S^3},$$

где μ_3^* – центральный момент 3-го порядка, $\bar{X}$ – среднее арифметическое; S – среднее квадратичное отклонение.


Центральный момент 3-го порядка $\mu_3^* = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^3$, где n – объем выборки

Для симметричной формы распределения коэффициент асимметрии равен нулю. Если $As^* > 0$, то данные имеют положительную асимметрию (правостороннюю), а если $As^* < 0$ – отрицательную (левостороннюю).



Правосторонняя

и



Левосторонняя асимметрия

Характеристики формы распределения

Следующий показатель – *эксцесс* – служит для характеристики так называемой крутости, т.е. островершинности или плосковершинности распределения.


Эксцессом называется величина, определяемая соотношением

$$Ex^* = \frac{\mu_4^*}{S_X^4} - 3.$$

где $\mu_4^* = \frac{\sum_{i=1}^n (X_i - \bar{X})^4}{n}$ - центральный момент

4 порядка

Если $Ex^* > 0$, распределение островершинное,
если $Ex^* < 0$ – плосковершинное. Чем больше $|Ex^*|$, тем сильнее отклонение высоты распределения от нормального ($Ex^* = 0$).



Квантили распределения

Квантилью порядка (или уровня) p называется такое значение вариационного ряда, которое отсекает долю выборки, равную p .

$$X_p^* = X_{([np])},$$

где операция $[\]$ – округление вверх (до большего целого).

Медиана – частный случай квантили. $Me = X_{0.5}^*$

Пример: дан вариационный ряд 3 4 5 6 7.

Найти квантили уровней 0,4 и 0,75.

$$X_{0.4}^* = X_{([5 \cdot 0,4])} = X_{(2)} = 4$$

$$X_{0.75}^* = X_{([5 \cdot 0,75])} = X_{([3,75])} = X_{(4)} = 6$$

Квартили распределения

Для нахождения квартилей нам необходимо вычислить значения номера элемента в вариационном ряду.

1 квартиль = это элемент, отсекающий 25% значений.

$$Q_1 = X_{0.25}^*$$

3 квартиль – это элемент, отсекающий 75% значений.

$$Q_3 = X_{0.75}^*$$

ПРИМЕР

Пример. Имеются сведения о производительности труда (в штуках) 10 работников: 8, 4, 9, 10, 10, 6, 6, 8, 5, 4. Построить вариационный ряд. Найти среднюю выработку, моду, медиану выработки, выборочную дисперсию, среднеквадратичное отклонение, коэффициент вариации, 1 и 3 квартили.

Решение. Объем выборки $n = 10$. Строим вариационный ряд, располагая исходные данные в порядке возрастания:

4, 4, 5, 6, 6, 8, 8, 9, 10, 10.

Найдем значения выборочных характеристик

Среднее арифметическое равно сумме значений всех вариантов выборки, деленной на объем выборки:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n x_i .$$

Здесь n – объем выборки, а x_i – варианты выборки.

Среднее $\bar{X} = \frac{1}{10} \cdot (8+4+9+10+10+6+6+8+5+4) = \frac{70}{10} = 7$, (штук)

Модой называется значение признака, встречающееся в выборке наиболее часто.

Условимся использовать для обозначения моды символы Mo .

$Mo = \{ 4, 6, 8 \text{ и } 10 \}$, (штук)

В случае несгруппированных данных для нахождения медианы необходимо ранжировать выборку, т. е. расположить данные в порядке их возрастания или убывания. Медианой будет являться значение признака, находящееся в середине ранжированного ряда. Медиана находится по формуле

$$M_e = \begin{cases} X_{\left(\frac{n+1}{2}\right)}, & \text{если } n - \text{нечетное,} \\ \frac{X_{\left(\frac{n}{2}\right)} + X_{\left(\frac{n}{2}+1\right)}}{2}, & \text{если } n - \text{четное.} \end{cases}$$

$Me = (6+8)/2 = 7$. (штук)

Выборочная дисперсия находится по формуле

$$S_X^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n}.$$

Используется также другая формула для вычисления дисперсии: $S_X^2 = \overline{X^2} - (\bar{X})^2$, где $\overline{X^2} = \frac{1}{n} \sum_{i=1}^n X_i^2$.

$$S_X^2 = \frac{1}{10} [(4-7)^2 + (4-7)^2 + (5-7)^2 + (6-7)^2 + (6-7)^2 + (8-7)^2 + (8-7)^2 + (9-7)^2 + (10-7)^2 + (10-7)^2] = 4,8 \text{ (штук в квадрате)}$$

Дисперсия имеет размерность квадрата размерности случайной величины, что затрудняет ее интерпретацию и делает не очень наглядной. Для более наглядного описания рассеяния удобнее пользоваться характеристикой, размерность которой совпадает с размерностью исследуемого признака. С этой целью вводится понятие **стандартного отклонения** (или **среднего квадратичного отклонения**).

Стандартным отклонением называется положительный квадратный корень из дисперсии:

$$S = \sqrt{S^2}.$$

Стандартное отклонение имеет те же единицы измерения, что и результаты измерения исследуемого признака, и, таким образом, оно характеризует степень отклонения признака от среднего арифметического. Иными словами, оно показывает, как расположена основная часть вариантов относительно среднего арифметического.

$$S_X = \sqrt{4,8} = 2,19. \text{ (штук)}$$

Коэффициент вариации равен отношению стандартного отклонения к среднему арифметическому и выражен в процентах:

$$V = \frac{S}{\bar{x}} 100\%.$$

Из определения ясно, что по своему смыслу коэффициент вариации представляет собой относительную меру рассеяния признака.

Коэффициент вариации используется для характеристики однородности полученных экспериментальных данных. Если ($V < 33\%$), то совокупность является однородной по изучаемому признаку и ее можно охарактеризовать средним значением. Если ($V \geq 33\%$), то совокупность неоднородная.

$$V = \frac{S_x}{\bar{X}} 100\% = \frac{2.19}{7} 100\% = 32.3\%.$$

Наша совокупность однородная, т.к. коэффициент вариации меньше 33 %. И можно сказать, что средняя выработка на предприятии составляет 7 штук.

Для нахождения квартилей нам необходимо вычислить значения номера элемента в вариационном ряду.

1 квартиль = это элемент, отсекающий 25% значений.

Берем объем выборки $n=10$ и умножаем на 0,25, получим $10 \cdot 0,25 = 2,5$. Берем следующий элемент по возрастанию: $Q1 = X_{(3)} = 5$ штук.

3 квартиль – это элемент, отсекающий 75% значений.

Берем объем выборки $n=10$ и умножаем на 0,75, получим $10*0,75=7,5$. Берем следующий элемент по возрастанию: $Q1 = X_{(8)} = 9$ штук.

Задание:

- 1) Лекция 1 - Все прочитать, вспомнить со 2 курса ТВ и МС все понятия, разобраться с примером.
- 2) Знать формулы нормального распределения (плотность распределения, функция, числовые характеристики, стр. 37-38)
- 3) Распечатать стр. 37-40 Лекция 1 и принести с собой
- 4) Распечатать статистические таблицы 1 и принести с собой
- 5) Составить таблицу (2 столбца, 1 столбец – теоритические числовые характеристики и формулы, 2 – эмпирические (выборочные числовые характеристики))