

Корреляционный анализ

Сущность методов корреляционного анализа

Корреляционный анализ — это совокупность методов оценивания степени тесноты статистической связи между анализируемыми переменными. Корреляционный анализ статистических данных включает в себя следующие основные практические приемы: вычисление выборочных корреляционных отношений или коэффициентов, проверка статистической гипотезы значимости связи и построение доверительных интервалов для корреляционных коэффициентов.

Предположим, что рассматриваемые признаки в генеральной совокупности имеют нормальное распределение и указанные данные представляют выборку из этой генеральной совокупности.

Корреляция — это зависимость

ПАРНЫЙ КОЭФФИЦИЕНТ КОРРЕЛЯЦИИ

Парный коэффициент корреляции характеризует **линейную взаимосвязь** между двумя переменными на фоне действия остальных показателей и является самым распространенным показателем тесноты связи при статистическом анализе данных.

Парный коэффициент корреляции между количественными случайными переменными X и Y носит название *выборочного коэффициента корреляции* Пирсона (*sample correlation coefficient*) (или просто коэффициента корреляции) и находится по формуле

$$r_*(X, Y) = \frac{K_*(X, Y)}{S_X \cdot S_Y} = \frac{K_*(X, Y)}{\sqrt{S_X^2 \cdot S_Y^2}},$$

где $S_X^2 = \overline{X^2} - (\overline{X})^2$ и $S_Y^2 = \overline{Y^2} - (\overline{Y})^2$ — *выборочные дисперсии (sample variances)* переменных X и Y , а $K_*(X, Y) = \overline{XY} - \overline{X} \cdot \overline{Y}$ — *выборочная ковариация* или выборочный ковариационный момент и соответствующие *средние (means)* определяются по формулам

$$\bar{X} = \frac{\sum_{i=1}^n x_i}{n}, \quad \bar{Y} = \frac{\sum_{i=1}^n y_i}{n}, \quad \overline{XY} = \frac{\sum_{i=1}^n x_i y_i}{n}, \quad \overline{X^2} = \frac{\sum_{i=1}^n x_i^2}{n}.$$

Коэффициент корреляции

обладает следующими свойствами:

- 1) Принимает значения от -1 до $+1$.
- 2) Знак коэффициента корреляции свидетельствует о направлении связи.
- 3) Знак «+» свидетельствует о прямой линейной зависимости между переменными X и Y , а знак «—» — об обратной линейной зависимости.
- 4) При $r_*(X, Y) = 0$ линейная корреляционная связь отсутствует.
- 5) Чем ближе коэффициент корреляции к ± 1 , тем сильнее связь.

Например, если коэффициент корреляции 0.89 или 0.92 — это сильная связь. А если 0.14 или -0.03 — это слабая связь.

- 6) Если $r_*(X, Y) = \pm 1$, то корреляционное поле наблюдений представляет собой совокупность точек, которые можно расположить на одной прямой.

Нет четких границ, которые определяют, при каких значениях слабая связь становится средней, а средняя – сильной.

Ориентировочно можно делать выводы согласно **классификации**, которую предложил математик **Чеддок**:


- слабая – от 0.1 до 0.3;
- умеренная – от 0.3 до 0.5;
- заметная – от 0.5 до 0.7;
- высокая – от 0.7 до 0.9;
- весьма высокая (сильная) – от 0.9 до 1.0.

Проблемы коэффициента корреляции Пирсона

- 1) Используется только, если данные имеют нормальное распределение, если нет, то он перестает быть эффективной оценкой
- 2) Служит мерой только линейной связи
- 3) Неустойчив к выбросам

Визуально можно примерно определить, сильная или слабая связь потому, насколько точки на диаграмме рассеяния (поле корреляции) стремятся выстроиться в одну линию.

Корреляция Пирсона



<http://guessthecorrelation.com/>

Интерпретация корреляции

- Важно понимать, что корреляция свидетельствует именно о **наличии взаимосвязи**, но ни в коем случае нельзя делать на основе корреляционного анализа выводы о причинно-следственных связях. Если между признаками А и Б есть тесная взаимосвязь, то мы не можем говорить, что А влияет на Б или Б влияет на А.

Например, мы ведем статистику по пожарам. Есть данные об **ущербе** и о **количестве пожарных**, которые тушили пожар. Скорее всего, между этими двумя признаками есть тесная взаимосвязь: при маленьком ущербе мало пожарных, при большом ущербе – много пожарных.

Но из этого не следует наличие причинно-следственных связей. Будет странным говорить, что пожарные приводят к убыткам. Такая взаимосвязь может наблюдаться из-за того, что на оба признака влияет третий – масштаб пожара. При серьезной ситуации будут большие потери, и на место тушения вызовут много бригад. Если же ситуация не критическая, то ущерб будет минимальный, и пожарных тоже будет мало. То есть, две величины меняются пропорционально, но совсем не из-за того, что одна из них влияет на другую.

Проверка гипотезы о значимости коэффициента корреляции

Проверка значимости коэффициента корреляции производится на основе критерия Стьюдента при заданном уровне значимости α .

При этом выдвигаем нулевую гипотезу $H_0: r(X, Y) = 0$ о том, что генеральный коэффициент корреляции равен нулю (или иначе: коэффициент корреляции генеральной совокупности незначим) (*statistically insignificant*), и конкурирующую гипотезу $H_1: r(X, Y) \neq 0$ о том, что генеральный коэффициент корреляции значим (*statistically significant*).

Фактическое значение ($K_{\text{выч}}$) t -статистики критерия

$$K_{\text{выч}} = \frac{r_*(Y, X) \cdot \sqrt{n-2}}{\sqrt{1 - r_*^2(Y, X)}}.$$

Найдем критическое значение статистики по табл. А3:

$$K_{\text{таб}} = t_{1-\alpha} [St(n-2)]$$

Гипотеза о значимости коэффициента корреляции отклоняется (т.е. принимаем гипотезу H_0), если $|K_{\text{выч}}| \leq K_{\text{таб}}$.

Пример. Рассмотрим методы корреляционного анализа на примере данных о цене товара (тыс. руб.) – X_1 , интенсивности потока покупателей (тыс. чел. в день) – X_2 и объеме продаж (тыс. шт.) – Y . Данные представлены в следующей таблице:

X_1	X_2	Y
1	2,3	7
2	2,5	7
3	3,5	6
4	2,4	5
5	2	3

Найти парный коэффициент корреляции между ценой товара и объемом продаж. На уровне значимости 0,05 проверить гипотезу о значимости генерального коэффициента корреляции. Построить 95%-й доверительный интервал для парного коэффициента корреляции.

Решение. Предположим, что рассматриваемые признаки Y, X_1, X_2 в генеральной совокупности имеют нормальное распределение и указанные данные представляют выборку из этой генеральной совокупности.

Определим коэффициент корреляции между Y и X_1 по формуле (3.1), для этого вычислим суммы

$$\sum_{i=1}^n X_{1i} = 15, \sum_{i=1}^n Y_i = 28, \sum_{i=1}^n X_{1i}^2 = 55, \sum_{i=1}^n Y_i^2 = 168, \sum_{i=1}^n X_{1i} Y_i = 74$$

и средние

$$\begin{aligned} \bar{X}_1 &= \frac{1}{n} \sum_{i=1}^n X_{1i} = \frac{15}{5} = 3, & \bar{Y} &= \frac{1}{n} \sum_{i=1}^n Y_i = \frac{28}{5} = 5,6, \\ \overline{X_1^2} &= \frac{1}{n} \sum_{i=1}^n X_{1i}^2 = \frac{55}{5} = 11, & \overline{Y^2} &= \frac{1}{n} \sum_{i=1}^n Y_i^2 = \frac{168}{5} = 33,6, \\ \overline{YX_1} &= \frac{1}{n} \sum_{i=1}^n X_{1i} Y_i = \frac{74}{5} = 14,8. \end{aligned}$$

Выборочные дисперсии будут равны

$$s_x^2 = \overline{X^2} - (\bar{X})^2 = 11 - 3^2 = 2, \quad s_{X1} = \sqrt{s_{X1}^2} = \sqrt{2} = 1,41,$$

$$S_Y^2 = \overline{Y^2} - (\bar{Y})^2 = 33,6 - 5,6^2 = 2,24, \quad S_Y = \sqrt{S_Y^2} = \sqrt{2,24} = 1,49.$$

Выборочная ковариация будет равна

$$K_*(Y, X_1) = \overline{YX_1} - \bar{X}_1 \cdot \bar{Y} = 14,8 - 3 \cdot 5,6 = -2.$$

Выборочный коэффициент корреляции между ценой товара и объемом продаж равен

$$r_*(Y, X_1) = \frac{K_*(Y, X_1)}{S_{X_1} \cdot S_Y} = \frac{-2}{1,41 \cdot 1,49} = -0,95,$$

что говорит о сильной линейной обратной взаимосвязи между переменными.

Проверим нулевую гипотезу $H_0 : r(X, Y) = 0$ о том, что генеральный коэффициент корреляции незначим, против конкурирующей гипотезы $H_1 : r(X, Y) \neq 0$ о том, что генеральный коэффициент корреляции значим.

Фактическое значение ($K_{\text{выч}}$) t -статистики критерия

$$K_{\text{выч}} = \frac{r_*(Y, X_1) \cdot \sqrt{n-2}}{\sqrt{1 - r_*^2(Y, X_1)}} = \frac{-0,95 \cdot \sqrt{5-2}}{\sqrt{1 - 0,95^2}} = 5,27.$$

Найдем критическое значение статистики по табл. А3:

$$K_{\text{маб}} = t_{1-\alpha}[St(n-2)] = t_{0,95}[St(3)] = x_{0,975}[St(3)] = 3,18.$$

Гипотеза о незначимости коэффициента корреляции отклоняется, поскольку $K_{\text{выч}} > K_{\text{таб}}$, т.е. на уровне значимости 0,05 можно утверждать, что коэффициент корреляции в генеральной совокупности значим.

Матрица парных коэффициентов корреляции


Парные коэффициенты корреляции могут быть вычислены для любых двух переменных X_j и Y , а также для X_j и X_i . На основе парных коэффициентов корреляции можно построить выборочную корреляционную матрицу:

$$Q = \begin{pmatrix} 1 & r_*(Y, X_1) & \dots & r_*(Y, X_m) \\ r_*(Y, X_1) & 1 & \dots & \dots \\ \dots & \dots & \dots & \dots \\ r_*(Y, X_m) & \dots & \dots & 1 \end{pmatrix}.$$

Данная матрица симметрична относительно главной диагонали и положительно определена.

Корреляционная матрица - в **первой строке и первом столбце** которой перечислены показатели, на **главной диагонали** – единицы, а **ячейки** содержат величины парных коэффициентов корреляции показателей строки и столбца.

Тепловая карта (англ. heatmap) — графическое представление данных, где индивидуальные значения в таблице отображаются при помощи цвета.



<https://machinelearningmastery.ru/formatting-tips-for-correlation-heatmaps-in-seaborn-4478ef15d87f/>

Пример. По данным предыдущей задачи оценке товара (тыс. руб.) – X_1 , интенсивности потока покупателей (тыс. чел. в день) – X_2 и объеме продаж (тыс. шт.) – Y построить матрицу корреляций.

Решение. Поскольку $r_*(Y, X_1) = -0,95$, $r_*(Y, X_2) = 0,39$, $r_*(X_1, X_2) = -0,19$, то корреляционная матрица будет иметь вид

$$\mathbf{Q} = \begin{pmatrix} 1 & r_*(X_1, X_2) & r_*(Y, X_1) \\ r_*(X_1, X_2) & 1 & r_*(Y, X_2) \\ r_*(Y, X_1) & r_*(Y, X_2) & 1 \end{pmatrix} = \begin{pmatrix} 1 & -0,19 & -0,95 \\ -0,19 & 1 & 0,39 \\ -0,95 & 0,39 & 1 \end{pmatrix}.$$

ЧАСТНЫЙ КОЭФФИЦИЕНТ КОРРЕЛЯЦИИ

Для первоначального отбора независимых переменных помимо парных коэффициентов корреляции часто используются также частные коэффициенты корреляции.

Частный коэффициент корреляции между переменными Y и X_j с исключением влияния на их связь всех остальных независимых переменных определяется по формуле

$$r_*(Y, X_j; \{X_i\} \setminus X_j) \equiv r_*(Y, X_j; \bullet) = \frac{-Q_{Y, X_j}}{\sqrt{Q_{X_j, X_j} \cdot Q_{Y, Y}}}, \quad (7)$$

в которой в левой части приведены символические обозначения выборочного частного коэффициента корреляции; Q_{Y, X_j} – алгебраическое дополнение коэффициента корреляции $r_*(Y, X_j)$ в выборочной корреляционной матрице $\mathbf{Q}$ переменных $Y, X_1, \dots, X_k$, Q_{X_j, X_j} – алгебраическое дополнение коэффициента корреляции $r_*(X_j, X_j) = 1$ в матрице $\mathbf{Q}$, $Q_{Y, Y}$ – алгебраическое дополнение коэффициента корреляции $r_*(Y, Y) = 1$ в матрице $\mathbf{Q}$. Частный коэффициент

корреляции используется для измерения силы «очищенной» линейной связи между двумя заданными переменными.

Такое применение частного коэффициента корреляции теоретически обосновано лишь в том случае, когда переменные $Y, X_1, \dots, X_k$ имеют совместное нормальное распределение. Во всех остальных случаях подобное использование носит эвристический характер.

Для трех переменных Y, X_1, X_2 формула (7) может быть записана в более простой форме:

$$r_*(Y, X_1; X_2) = \frac{r_*(Y, X_1) - r_*(Y, X_2) \cdot r_*(X_1, X_2)}{\sqrt{(1 - r_*^2(Y, X_2))(1 - r_*^2(X_1, X_2))}}. \quad (8)$$

Пример. По данным предыдущего примера найти частный коэффициент корреляции $r_*(Y, X_1|X_2)$.

Решение. Поскольку корреляционная матрица имеет вид

$$Q = \begin{pmatrix} 1 & r_*(X_1, X_2) & r_*(Y, X_1) \\ r_*(X_1, X_2) & 1 & r_*(Y, X_2) \\ r_*(Y, X_1) & r_*(Y, X_2) & 1 \end{pmatrix} = \begin{pmatrix} 1 & -0,19 & -0,95 \\ -0,19 & 1 & 0,39 \\ -0,95 & 0,39 & 1 \end{pmatrix},$$

а алгебраические дополнения

$$Q_{Y, X_1} = (-1)^{1+3} \cdot \begin{vmatrix} -0,19 & 1 \\ -0,95 & 0,39 \end{vmatrix} = -0,19 \cdot 0,39 + 0,95 \cdot 1 = 0,8759,$$

$$Q_{X_1, X_1} = (-1)^{1+1} \cdot \begin{vmatrix} 1 & 0,39 \\ 0,39 & 1 \end{vmatrix} = 1 - 0,39^2 = 0,8479,$$

$$Q_{Y, Y} = (-1)^{3+3} \cdot \begin{vmatrix} 1 & -0,19 \\ -0,19 & 1 \end{vmatrix} = 1 - 0,19^2 = 0,9639,$$

частный коэффициент корреляции будет равен

$$r_*(Y, X_1|X_2) = \frac{-Q_{Y, X_1}}{\sqrt{Q_{X_1, X_1} \cdot Q_{Y, Y}}} = \frac{-0,8759}{\sqrt{0,8479 \cdot 0,9639}} = -0,9689,$$

что говорит об очень тесной обратной линейной связи между ценой товара и объемами продаж при фиксированной интенсивности потока покупателей.

Или по упрощенной формуле

$$r_*(Y, X_1|X_2) = \frac{r_*(Y, X_1) - r_*(Y, X_2) \cdot r_*(X_1, X_2)}{\sqrt{(1 - r_*^2(Y, X_1)) \cdot (1 - r_*^2(X_1, X_2))}} = \frac{-0,95 - (-0,19) \cdot 0,39}{\sqrt{(1 - 0,19^2) \cdot (1 - 0,39^2)}} \\ = -0,9689.$$

Порядок частного коэффициента корреляции будет равен единице ($k = 1$), т.к. количество зафиксированных переменных равно 1 (это переменная X_2).

ПРОВЕРКА ГИПОТЕЗЫ О ЗНАЧИМОСТИ ЧАСТНОГО КОЭФФИЦИЕНТА КОРРЕЛЯЦИИ

Проверка значимости частного коэффициента корреляции производится на основе критерия Стьюдента при заданном уровне значимости α , приведенного в п. 3, но при этом объем выборки n заменяется на $n - k$, где k – порядок частного коэффициента корреляции (сколько переменных зафиксировано).

Для проверки гипотезы $H_0: r(X_j, Y; \bullet) = 0$ о том, что генеральный частный коэффициент корреляции равен нулю (или иначе: коэффициент корреляции

генеральной совокупности незначим), фактическое значение ($K_{выч}$) t -статистики критерия Стьюдента находится по формуле

$$t = \frac{r_*(X_j, Y; \bullet) \sqrt{n - k - 2}}{\sqrt{1 - r_*^2(X_j, Y; \bullet)}}. \quad (9)$$

t -статистика имеет распределение Стьюдента с числом степеней свободы $n - k - 2$, поэтому критическое значение ($K_{маб}$) статистики критерия — двусторонняя квантиль уровня $1 - \alpha$ распределения Стьюдента с числом степеней свободы $(n - k - 2)$ — находится по табл. 2:

$$K_{маб} = t_{1-\alpha/2}(n - k - 2) \quad (10)$$

Гипотеза о значимости коэффициента корреляции отклоняется (т.е. принимаем гипотезу H_0), если $|K_{выч}| \leq K_{маб}$.

Пример. На уровне значимости 0,05 проверить гипотезу о значимости частного коэффициента корреляции $r_*(Y, X_1|X_2)$.

Решение. Проверим гипотезу $H_0: r(Y, X_1|X_2) = 0$ (частный коэффициент корреляции в генеральной совокупности незначим) против конкурирующей $H_0: r(Y, X_1|X_2) \neq 0$ (частный коэффициент корреляции в генеральной совокупности значим).

Вычисленное значение статистики критерия равно

$$K_{\text{выч}} = \frac{r_*(Y, X_1|X_2)\sqrt{n - k - 2}}{\sqrt{1 - r_*^2(Y, X_1|X_2)}} = \frac{-0,9689\sqrt{5 - 1 - 2}}{\sqrt{1 - 0,9689^2}} = -5,54.$$

Критическое значение статистики находится по табл. А3:

$$K_{\text{таб}} = t_{1-0,05}[St(5 - 1 - 2)] = t_{0,95}[St(2)] = 4,3.$$

Поскольку $|K_{\text{выч}}| > K_{\text{выч}}$, то гипотезу о значимости частного коэффициента корреляции принимаем на уровне значимости 0,05.

МНОЖЕСТВЕННЫЙ КОЭФФИЦИЕНТ КОРРЕЛЯЦИИ. ПРОВЕРКА ГИПОТЕЗЫ О ЗНАЧИМОСТИ МНОЖЕСТВЕННОГО КОЭФФИЦИЕНТА КОРРЕЛЯЦИИ

Множественный коэффициент корреляции $R_{y.X}$ используется в качестве измерителя статистической связи между результирующим показателем Y и набором объясняющих переменных $X_1, \dots, X_k$ (линейная форма зависимости Y от набора $X_1, \dots, X_k$). Он показывает долю дисперсии рассматриваемой величины Y , обусловленную влиянием остальных переменных $X_1, \dots, X_k$, включенных в корреляционную модель.

$R_{y.X}$ вычисляется по матрице парных коэффициентов корреляции Q следующим образом:
$$R_{y.X} = \sqrt{1 - \frac{|Q|}{Q_{YY}}}, \quad (11)$$

где $|Q|$ — определитель матрицы корреляций Q , а $Q_{Y,Y}$ — алгебраическое дополнение.

Проверка гипотезы о значимости множественного коэффициента корреляции осуществляется на основе критерия Фишера.

При этом проверяется нулевая гипотеза: $H_0: R_{y.X} = 0$ (коэффициент множественной корреляции генеральной совокупности равен нулю) при конкурирующей гипотезе: $H_1: R_{y.X} \neq 0$.

Значение $K_{\text{выч}}$ статистики F -критерия находится по формуле

$$F = \frac{R_{y,X}^2}{1 - R_{y,X}^2} \cdot \frac{n - k - 1}{k}, \quad (12)$$

где k — число факторных переменных. При условии справедливости нулевой гипотезы F -статистика критерия имеет распределение Фишера с $\nu_1 = k$ и $\nu_2 = n - k - 1$ степенями свободы. Критическое значение статистики определяется формулой $K_{\text{таб}} = x_{1-\alpha}[F(k, n - k - 1)]$ (13)

и находится по табл. 5 и 6.

Если $K_{\text{выч}} < K_{\text{таб}}$, то гипотезу о незначимости модели H_0 следует принять, т.е. нет оснований ее отклонить. Если $K_{\text{выч}} \geq K_{\text{таб}}$, то гипотезу о незначимости H_0 следует отклонить.

Пример. Определить силу влияния цены товара и интенсивности потока покупателей на объем продаж с помощью множественного коэффициента корреляции. На уровне значимости 0,05 проверить значимость множественного коэффициента корреляции.

Решение. Поскольку корреляционная матрица имеет вид

$$Q = \begin{pmatrix} 1 & r_*(X_1, X_2) & r_*(Y, X_1) \\ r_*(X_1, X_2) & 1 & r_*(Y, X_2) \\ r_*(Y, X_1) & r_*(Y, X_2) & 1 \end{pmatrix} = \begin{pmatrix} 1 & -0,19 & -0,95 \\ -0,19 & 1 & 0,39 \\ -0,95 & 0,39 & 1 \end{pmatrix},$$

определитель будет $|Q| = 1 + (-0,95) \cdot (-0,19) \cdot 0,39 + (-0,95) \cdot (-0,19) \cdot 0,39 - (-0,95)^2 - 0,39^2 - (-0,19)^2 = 0,05$,

а алгебраическое дополнение

$$Q_{Y,Y} = (-1)^{3+3} \cdot \begin{vmatrix} 1 & -0,19 \\ -0,19 & 1 \end{vmatrix} = 1 - 0,19^2 = 0,9639.$$

Тогда множественный коэффициент корреляции будет равен

$$R_{Y.X} = \sqrt{1 - \frac{|Q|}{Q_{Y,Y}}} = \sqrt{1 - \frac{0,05}{0,9639}} = 0,974.$$

На уровне значимости 0,05 проверим гипотезу о незначимости множественного коэффициента корреляции $H_0: R_{y.X} = 0$ против конкурирующей $H_1: R_{y.X} \neq 0$.

Вычисленное значение статистики для проверки гипотезы будет равно

$$K_{\text{выч}} = \frac{R_{Y.X}^2}{1 - R_{Y.X}^2} \cdot \frac{n - k - 1}{k} = \frac{0,974^2}{1 - 0,974^2} \cdot \frac{5 - 2 - 1}{2} = 18,48,$$

где $k = 2$ – число факторных переменных (в нашем случае это X_1, X_2).

Критическое значение статистики находится по табл. А6 и равно

$$K_{\text{табл}} = x_{1-0,05}[F(2,2)] = 19,0.$$

Поскольку $K_{\text{выч}} < K_{\text{табл}}$, то гипотезу о незначимости модели следует принять.

Непараметрические показатели связи

В статистической практике приходится сталкиваться с задачами измерения связи между качественными признаками, к которым параметрические методы анализа в их обычном виде неприменимы. Разработаны методы, с помощью которых можно измерить связь между явлениями, не используя при этом количественные значения признака, а значит, и параметры распределения. Такие методы получили название *непараметрических*.

Не всегда исследуемые показатели являются количественными, т.е. имеющими числовые значения.

Иногда показатели являются **качественными**, т.е. принимающими значения из какой-то **номинальной шкалы (шкалы наименований)**.


Ранговый коэффициент корреляции Спирмена

Среди непараметрических методов оценки тесноты связи наибольшее значение имеют ранговые коэффициенты Спирмена и Кенделла. Эти коэффициенты могут быть использованы для определения тесноты связи как между количественными (которые не имеют нормального распределения), так и между качественными признаками. Метод ранговой корреляции Спирмена позволяет определить тесноту (силу) и направление корреляционной связи между двумя признаками (как количественными, так и качественными). Коэффициент ранговой корреляции имеет границы изменения от -1 до $+1$. Полное совпадение рангов означает максимально тесную прямую связь, полная противоположность рангов – максимально тесную обратную связь. Формула расчета **коэффициента корреляции рангов Ч. Спирмена**:

$$\rho_s^* = 1 - \frac{6}{n^3 - n} \cdot \sum_{i=1}^n [R(X_i) - R(Y_i)]^2,$$

где $R(z_i)$ – ранг z_i в выборке $z_1, z_2, \dots, z_n$.

Корреляция Спирмена



Проверка гипотезы о значимости рангового коэффициента корреляции Спирмена

Проверяется гипотеза $H_0: \rho_s = 0$ (ранговый коэффициент корреляции незначим в генеральной совокупности) против конкурирующей $H_0: \rho_s \neq 0$.

При достаточно большом объеме выборки гипотеза H_0 принимается, если $K_{\text{выч}} < t_{1-\alpha}[N]$, где $K_{\text{выч}} = |\rho_s| \sqrt{n-1}$.

Ранговый коэффициент корреляции Кенделла

Использование коэффициента корреляции Спирмена имеет недостаток. При вычислении ρ_s^* мы должны были находить разность между значениями рангов, но в ряде случаев эта операция бессмысленна (например, разность между 1-м и 2-м местами на соревнованиях не соответствует разности между 10-м и 11-м местами). Этому недостатка лишен **коэффициент ранговой корреляции Кенделла**.

Формула расчета коэффициента корреляции рангов Кендалла:

$$\tau = \frac{2 \cdot S}{n(n-1)},$$

где $S = \sum Q - \sum P$; n – общее число наблюдений. Параметры Q и P определяются для последовательности наблюдений, предварительно упорядоченных по возрастанию ранга признака X . Далее для каждого наблюдения в отдельности определяются Q – число случаев, когда у последующих наблюдений ранг признака Y больше, чем у данного, и P – число случаев, когда у последующих наблюдений ранг признака Y меньше, чем у данного.

ПРИМЕРЫ:

1. Известны следующие результаты наблюдений:

$$n = 10, \sum_{i=1}^n X_i = 30, \sum_{i=1}^n Y_i = 80, \sum_{i=1}^n X_i Y_i = 270, \sum_{i=1}^n X_i^2 = 100, \sum_{i=1}^n Y_i^2 = 1000.$$

Определить выборочный коэффициент корреляции и построить 95%-й доверительный интервал для генерального коэффициента корреляции. На уровне значимости 0,05 проверить гипотезу о значимости коэффициента корреляции.

2. Известны следующие результаты наблюдений:

$$n = 20, \bar{X} = 15, \bar{Y} = 12, \sum_{i=1}^n X_i Y_i = 3900, \sum_{i=1}^n X_i^2 = 5000, \sum_{i=1}^n Y_i^2 = 3600.$$

Определить

выборочный коэффициент корреляции и построить 98%-й доверительный интервал для генерального коэффициента корреляции. На уровне значимости 0,05 проверить гипотезу о значимости коэффициента корреляции.

3. Экспертами оценивались вложения в инвестиционные проекты. Суммарные оценки представлены в таблице

Проект	Первый эксперт	Второй эксперт
1	11	10
2	14	13
3	17	17
4	15	14
5	13	12
6	13	13
7	18	16
8	10	11
9	19	20
10	25	22

Определить, согласуются ли оценки экспертов, с помощью рангового коэффициента корреляции Спирмена, Кендалла. Сделать выводы.

Анализ таблиц сопряженности

Если изучается взаимосвязь двух качественных признаков, то используют комбинационное распределение единиц совокупности в форме так называемых *таблиц взаимной сопряженности*. **Таблица сопряжённости** или факторная таблица— средство представления совместного распределения двух [переменных](#), предназначенное для исследования связи между ними. Таблица сопряжённости является наиболее универсальным средством изучения статистических связей, так как в ней могут быть представлены переменные с любым уровнем измерения. Наиболее простой вариант – это таблица сопряженности размера (2×2) .

Первый признак	Второй признак		Итого
	Да(B)	Нет($\bar{B}$)	
Да(A)	a	b	$a + b$
Нет($\bar{A}$)	c	d	$c + d$
Итого	$a + c$	$b + d$	$n = a + b + c + d$

В ней признаки, представленные двумя альтернативными вариантами, причем a , b , c , d – количество объектов (наблюдений) или частота совместного появления вариантов признака.

Для характеристики тесноты связи между признаками используются *коэффициент ассоциации Юла* и *коэффициент контингенции Пирсона*.

Коэффициент ассоциации Юла рассчитывается по формуле

$$K_{as} = \frac{a \cdot d - c \cdot b}{a \cdot d + c \cdot b}.$$

Коэффициент ассоциации изменяется в интервале от -1 до +1. Условно можно оценить и направление связи: *положительная величина* коэффициента ассоциации означает, что при переходе от значения A_k значению $\bar{A}$ отмечается предпочтительный переход единиц совокупности от значения признака B_k значению признака $\bar{B}$. Коэффициент ассоциации не изменяется при умножении строки или столбца на произвольную положительную постоянную величину.

Коэффициент контингенции Пирсона находится по формуле

$$K_{kon} = \frac{a \cdot d - c \cdot b}{\sqrt{(a + b)(a + c)(b + d)(c + d)}}.$$

Коэффициент контингенции также изменяется в интервале от -1 до +1, хотя всегда меньше коэффициента ассоциации, т.е. дает более осторожную оценку тесноты связи. Связь считается достаточно значимой и подтвержденной, если $|K_{as}| > 0,5$ или $|K_{kon}| > 0,3$.

Пример. Исследовалась связь между успеваемостью студентов-заочников одного из вузов и работой их по специальности. Результаты исследования приведены в таблице

Студенты-заочники	Число студент ов	Из них	
		получившие положительн ые оценки	получившие неудовлетвори тельные оценки
Работающие по специальности	200	180	20
Не работающие по специальности	200	140	60
Итого	400	320	80

Определить тесноту связи между признаками, используя коэффициент ассоциации Юла и коэффициент контингенции Пирсона.

Решение. Коэффициент ассоциации Юла будет равен

$$K_{as} = \frac{a \cdot d - c \cdot b}{a \cdot d + c \cdot b} = \frac{180 \cdot 60 - 140 \cdot 20}{180 \cdot 60 + 140 \cdot 20} = 0,6.$$

Коэффициент контингенции Пирсона будет

$$K_{kon} = \frac{a \cdot d - c \cdot b}{\sqrt{(a+b)(a+c)(b+d)(c+d)}} = \frac{180 \cdot 60 - 140 \cdot 20}{\sqrt{(180+20)(20+60)(60+140)(140+180)}} = 0,4.$$

Из расчетов видно, что связь между успеваемостью студентов-заочников и работой их по специальности достаточно сильная.

Для оценки тесноты связи между альтернативными признаками, принимающими любое число вариантов значений (т.е. для таблиц сопряженности размера $(k_1 \times k_2)$, применяется **коэффициент взаимной сопряженности К. Пирсона и А.А.Чупрова**. Первичная статистическая информация для исследования этой связи представлена в табличной форме:

Первый признак	Второй признак				Итого
	B_1	B_2	B_3	...	
A_1	n_{11}	n_{12}	n_{13}	...	$\sum n_{1j}$
A_2	n_{21}	n_{22}	n_{23}	...	$\sum n_{2j}$
A_3	n_{31}	n_{32}	n_{33}	...	$\sum n_{3j}$
...	...	...	...	...	
Итого	$\sum n_{i1}$	$\sum n_{i2}$	$\sum n_{i3}$		n

где n_{ij} – частоты взаимного сочетания двух атрибутивных признаков; n – число пар наблюдений.

Коэффициент взаимной сопряженности Пирсона определяется по формуле

$$K_{Pirson} = \sqrt{\frac{\varphi^2}{\varphi^2 + 1}}.$$

Коэффициент взаимной сопряженности Чупрова определяется по формуле

$$K_{Chuprov} = \sqrt{\frac{\varphi^2}{(k_1 - 1)(k_2 - 1)}},$$

где φ^2 – показатель взаимной сопряженности; k_1 и k_2 – число строк и столбцов в таблице. Показатель взаимной сопряженности рассчитывается как

$$\varphi^2 = \left(\frac{n_{11}^2}{\sum n_{1j} \sum n_{i1}} + \frac{n_{21}^2}{\sum n_{2j} \sum n_{i2}} + \dots + \frac{n_{33}^2}{\sum n_{3j} \sum n_{i3}} + \dots \right) - 1.$$

Коэффициенты взаимной сопряженности изменяются от 0 до 1. Чем ближе коэффициенты к единице, тем сильнее взаимосвязь между признаками.

Проверка независимости двух переменных с помощью таблицы сопряженности

Пусть X, Y – две случайные номинальные переменные; $A_1, \dots, A_k$ – значения (уровни) переменной X , $B_1, \dots, B_l$ – значения (уровни) переменной Y . Обозначим через n_{ij} – количество наблюдений, в которых появилась пара (A_i, B_j) , $n = \sum_{i=1}^k \sum_{j=1}^l n_{ij}$. Множество значений переменных и их частот, представленных в виде таблице, часто называют таблицей сопряженности $k \times l$. Необходимо на уровне значимости α выяснить, существует ли связь между переменными X и Y .

Для проверки гипотезы обычно используется статистика хи-квадрат вида

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^l \frac{(n_{ij} - \tilde{n}_{ij})^2}{\tilde{n}_{ij}}, \quad \text{где} \quad \tilde{n}_{ij} = n \cdot \frac{a_i}{n} \cdot \frac{b_j}{n} = \frac{a_i b_j}{n}.$$

Здесь $a_i = \sum_{j=1}^l n_{ij}$ – сумма элементов i -й строки матрицы наблюдений $\|n_{ij}\|$, $b_j = \sum_{i=1}^k n_{ij}$ – сумма элементов j -й строки матрицы наблюдений $\|n_{ij}\|$.

Гипотеза независимости принимается, если выполняется неравенство $\chi_{\text{выч}}^2 < \chi_{1-\alpha}^2(\nu)$, значение правой части которого определяется по уровню значимости α и числу степеней свободы $\nu = (k-1)(l-1)$.