

МЕТОДЫ КЛАССИФИКАЦИИ МНОГОМЕРНЫХ НАБЛЮДЕНИЙ

Сущность задач классификации

В процессе решения широкого круга социально-экономических исследовательских и управленческих задач возникает необходимость анализа и формализации задач, связанных со сравнением и классификацией объектов, явлений, систем.

Под **классификацией** понимают разделение рассматриваемой совокупности объектов или явлений на однородные, в определенном смысле, группы либо отнесение каждого объекта (из заданного множества классифицируемых объектов) к одному из заранее известных классов.

Цель методов классификации заключается в «сжатии» системы N объектов, каждый из которых характеризуется k -мерным вектором признаков таким образом, чтобы не потерять существенную информацию об этой системе. Для этого выявляются классы (группы) сходных между собой объектов.

Среди прикладных задач, решаемых указанными методами, отметим следующие:

- проведение классификации объектов с учетом большого числа признаков, отражающих их природу;
- выявление структуры изучаемой совокупности объектов;
- снижение объема выборки путем отождествления каждого класса объектов с его типичным представителем;
- снижение размерности пространства путем отождествления близких признаков (в этом случае классифицируются не объекты, а признаки; в многомерном статистическом анализе этот прием перемены объектов и признаков местами часто приводит к интересным результатам);
- построение отдельных регрессионных моделей в каждом классе объектов; если дисперсия остатков регрессии сильно изменяется от класса к классу (такое явление называется *гетероскедастичностью*), то построение регрессии для каждого класса может помочь избавиться от гетероскедастичности.

Формально задача классификации ставится следующим образом. Имеется исходное множество $G = \{X_1, X_2, \dots, X_N\}$, состоящее из N k -мерных объектов $X_i^T = \{x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(k)}\}$, $i = 1, 2, \dots, N$. Требуется разбить множество G на m подмножеств (кластеров) $G_1, G_2, \dots, G_m$ таких, что $G_i \cap G_j = \emptyset$, $\bigcup_{i=1}^m G_i = G$. При этом требуется, чтобы в

один кластер попали похожие (близкие) объекты, а в разные – наиболее несхожие (далекие объекты). Иначе говоря, в каждом отдельном кластере объекты должны быть однородными, а в различных – разнородными. При этом число возможных кластеров m может быть априори известным и неизвестным.

Кластерный анализ решает задачу классификации объектов при отсутствующей априорной информации о наблюдениях внутри классов, если же обучающие выборки имеются в распоряжении исследователя, то решается задача классификации при наличии обучения (или задача распознавания образов) и используются для ее решения методы *дискриминантного анализа*.

Кластерный анализ

Методы *кластерного анализа* позволяют разбить изучаемую совокупность объектов на группы однородных в некотором смысле объектов, называемых *кластерами* или *классами*. Наибольшее распространение получили два подхода к задаче классификации: *эвристический*, реализующий некоторую схему разделения объектов на классы исходя из

интуитивных соображений, и **экстремальный**, реализующий схему разделения на основе заданного критерия оптимальности.

Приведем примеры задач, решаемых с помощью кластерного анализа: определение групп потребителей и сегментирование рынков, распределение регионов по экономическим показателям, определение групп потенциальных заемщиков в крупных кредитных организациях для принятия решений, распределение товаров на группы схожих и т.п.

Этапы кластерного анализа:

1 этап. Это спецификация проблемы, т.е. выбор переменных, которые будут использоваться при анализе и преобразование переменных.

2 этап. Выбор расстояния и меры сходства между объектами.

3 этап. Выбор расстояния между классами.

Методы кластерного анализа рекомендуется использовать на 2-м этапе статистического анализа данных.

Замечание. В большинстве видов статистического анализа данные обычно подвергаются нормировке некоторым подходящим способом. Не исключение и кластерный анализ. В том случае, если данные измерены в разных масштабах, нормировка обычно производится таким образом, чтобы среднее равнялось нулю, а дисперсия – единице. Для этого используется следующее преобразование:

$$\tilde{x}_{il} = \frac{x_{il} - \bar{x}_l}{S_l}, \quad i=1,2,\dots,N; \quad l=1,2,\dots,k,$$

где x_{il} – значение l -го признака объекта X_i ; $\bar{x}_l$ – среднее значение l -го признака; S_l – среднее квадратичное отклонение l -го признака.

Решение о проведении нормировки должно приниматься с учетом специфики решаемой задачи, при этом пользователь должен понимать, что результаты могут различаться в зависимости от принятого решения.

Расстояния и меры сходства между объектами

Весьма важным моментом для процесса классификации является тот факт, что между любыми объектами всегда существует сходство или различие. В основе понятия сходства или близости объектов лежит понятие расстояния, которое определяется в k -мерном пространстве. Размерность пространства определяется числом признаков, использованных для описания объектов. Кроме того, для определения сходства или различия между объектами можно использовать так называемую меру сходства, которая имеет прямо противоположный смысл мере расстояния.

К наиболее известным расстояниям, используемым при конструировании процедур кластерного анализа, относятся:

1) Евклидово расстояние $d(X, Y) = \sqrt{\sum_{i=1}^k (x_i - y_i)^2}$.

Если вы имеете двух- трехмерное пространство, то эта мера является реальным геометрическим расстоянием между объектами в пространстве.

2) Взвешенное евклидовое расстояние

$$d(X, Y) = \sqrt{\sum_{i=1}^k \omega_i (x_i - y_i)^2}$$

применяется в ситуациях, в которых удастся приписать каждой из компонент вектора наблюдений (объекта) некоторый вес, пропорциональный степени его важности с точки зрения решения вопроса об отнесении объекта к тому или иному кластеру. При этом $\omega_i \geq 0$, $i=1,\dots,k$, и удовлетворяют некоторому условию нормировки, например, $\sum_{i=1}^k \omega_i = 1$

или $\sum_{i=1}^k \omega_i = k \cdot$

3) *l₁-норма* $d_1(X, Y) = \sum_{i=1}^k |x_i - y_i|$.

В большинстве случаев применение этого расстояния при построении процедур кластерного анализа приводит к таким же результатам, как и применение обычного расстояния Евклида. Однако для этой меры влияние отдельных больших разностей (выбросов) уменьшается (так как они не возводятся в квадрат).

Если исходные данные представляют собой булевы переменные, то расстояние, вычисленное по этой формуле, носит название *Хемингово расстояние* (его значение равно числу несовпадений признаков в рассматриваемой паре объектов), это же расстояние можно использовать и для количественных признаков, при этом его называют *расстоянием городских кварталов* (или, в шутку, *дистанцией манхеттенского таксиста*), в этом случае $d(X, Y)$ — это не кратчайшее расстояние между двумя точками, а «путь, который должен преодолеть таксист, чтобы проехать от одной точки до другой по городским улицам, пересекающимся, как в Манхеттене, под прямым углом»).

4) *Супремум-норма* $d_\infty(X, Y) = \sup_{i=1, 2, \dots, k} |x_i - y_i|$.

5) *Степенное расстояние или l_p-норма*

$$d_p(X, Y) = \left(\sum_{i=1}^k |x_i - y_i|^p \right)^{1/p}.$$

Это расстояние целесообразно использовать в случае, когда есть желание увеличить или уменьшить вклад в сходство, относящийся к тому признаку, по которому рассматриваемые объекты сильно различаются. Параметр p определяется исследователем.

6) *Расстояние Махаланобиса*

$$d(X, Y) = \sqrt{(X - Y)' \Sigma^{-1} (X - Y)}.$$

Здесь Σ — некоторая положительно определенная симметричная матрица порядка $(k \times k)$, например ковариационная матрица между объектами X и Y .

Замечание. Методы кластерного анализа могут использоваться и для *классификации признаков*. В качестве мер однородности признаков обычно используются характеристики степени их коррелированности:

- коэффициенты корреляции;
- коэффициенты ранговой корреляции;
- коэффициенты контингенции и т. п.

Расстояние между классами

Расстояние между множествами объектов представляет собой функционал, который зависит от расстояния или меры сходства между объектами, составляющими эти множества.

Наиболее известными и наиболее общими расстояниями между множествами объектов S_l и S_t являются:

1) *Расстояние, измеряемое по принципу «ближнего соседа»:*

$$\rho_{\min}(S_l, S_t) = \min_{X \in S_l, Y \in S_t} d(X, Y).$$

2) *Расстояние, измеряемое по принципу «дальнего соседа»:*

$$\rho_{\max}(S_l, S_t) = \max_{X \in S_l, Y \in S_t} d(X, Y).$$

3) Расстояние, измеряемое по центрам тяжести групп:

$$\rho(S_l, S_t) = d(\bar{X}(l), \bar{X}(t)),$$

где вектор $\bar{X}(i)$ – среднее арифметическое векторных наблюдений, входящих в группу S_i .

4) Расстояние, измеряемое по принципу «средней связи», определяется как арифметическое среднее всевозможных попарных расстояний между представителями рассматриваемых групп, т.е.

$$\rho_{cp}(S_l, S_t) = \frac{1}{n_l n_t} \sum_{X \in S_l} \sum_{Y \in S_t} d(X, Y).$$

5) Обобщенное расстояние между классами, или обобщенное K -расстояние, вычисляется по формуле

$$\rho_{\tau}^{(K)}(S_l, S_t) = \left[\frac{1}{n_l n_t} \sum_{X \in S_l} \sum_{Y \in S_t} d^{\tau}(X, Y) \right]^{\frac{1}{\tau}}.$$

Функционалы качества разбиения множеств на кластеры

Сравнить качество различных способов разбиения можно вводом в постановку задачи кластерного анализа функционала качества разбиения $\psi(S)$, определенного на множестве всех возможных разбиений.

Функционал качества разбиения – это любая функция от исходного множества наблюдений, количества кластеров или их элементов, которая может служить критерием качества разбиения. Явно или неявно она используется в любом методе кластерного анализа. Однозначного определения функционала качества разбиения не существует. В большинстве кластер-процедур функционалы качества разбиения представляют собой меры внутриклассового либо межклассового рассеяния. Многие из рассмотренных в предыдущем параграфе расстояний между множествами объектов сами являются функционалами качества разбиения множеств на кластеры. Наилучшим разбиением считается разбиение S^* , на котором достигается экстремум выбранного функционала качества.

Иногда название процедур кластерного анализа определяется названием функционала качества разбиения, на основании которого делается вывод о наиболее оптимальном разбиении данного множества объектов на кластеры, как в случае использования функционалов типа «ближнего соседа», «дальнего соседа», «средней связи».

Кроме того, приведем еще некоторые функционалы, которые чаще, чем другие, используются при решении задачи кластерного анализа.

1) Сумма внутриклассовых дисперсий:

$$\psi_1(S) = \sum_{l=1}^m \sum_{X_i \in S_l} d^2(X_i, \bar{X}(l)).$$

2) Сумма попарных внутриклассовых расстояний между элементами:

$$\psi_2(S) = \sum_{l=1}^m \sum_{X_i, X_j \in S_l} d^2(X_i, X_j).$$

3) Обобщенная внутриклассовая дисперсия:

$$\psi_3(S) = \det\left(\sum_{l=1}^m n_l W_l\right),$$

где $\det A$ – определитель матрицы, W_l – выборочная ковариационная матрица по наблюдениям, попавшим в S_l , элементы которой вычисляются по формуле

$$w_{qr}(l) = \frac{1}{n_l} \sum_{X_i \in S_l} (x_i^{(q)} - \bar{x}^{(q)}(l))(x_i^{(r)} - \bar{x}^{(r)}(l)), \quad q, r = 1, 2, \dots, k, \quad x_i^{(v)} - v\text{-я компонента}$$

наблюдения X_i , а $\bar{x}^{(v)}(l)$ – среднее значение v -й компоненты, подсчитанное по всем наблюдениям, входящим в группу S_l , n_l – количество наблюдений, содержащихся в группе S_l .

Еще один вариант использования понятия обобщенной дисперсии как характеристики качества разбиения встречается в виде

$$\psi_4(S) = \prod_{l=1}^m (\det W_l)^{n_l}.$$

4) Средняя мера внутриклассового рассеяния Колмогорова

$$I_\tau^{(K)}(S) = \left\{ \frac{1}{N} \sum_{i=1}^m n_i [Q_\tau^{(K)}(S_i)]^\tau \right\}^{\frac{1}{\tau}},$$

где $Q_\tau^{(K)}(S_i) = \left\{ \frac{1}{N^2} \sum_{X_j \in S_i} \sum_{X_l \in S_i} d^\tau(X_j, X_l) \right\}^{\frac{1}{\tau}}.$

Числовой параметр τ выбирается по усмотрению исследователя.

Наилучшим разбиением с точки зрения использования вышеприведенных функционалов для оценки качества разбиения множества на кластеры будет считаться то, при котором будет достигнут минимум этих функционалов.

5) Сумма межклассовых дисперсий:

$$\psi_5(S) = \sum_{j=1}^m \sum_{l>j}^m d^2(\bar{X}(j), \bar{X}(l)).$$

6) Сумма попарных межклассовых расстояний:

$$\psi_6(S) = \sum_{l=1}^m \sum_{j>l}^m \frac{1}{n_j n_l} \sum_{X_i \in S_j, X_r \in S_l} d^2(X_i, X_r)$$

При использовании этих функционалов вывод о наилучшем разбиении делается, если достигается их максимальное значение.

В случае когда исследователю заранее неизвестно, на какое число классов делится исходное множество наблюдений, параметр m становится дополнительным оптимизационным параметром функционала качества разбиения $\psi(S)$. Последовательное использование различных значений этого параметра дает возможность найти наиболее оптимальное разбиение исходного множества.

Иерархические методы

Иерархические методы кластеризации бывают двух видов:

- агломеративные, которые заключаются в последовательном объединении двух наиболее схожих кластеров в один;
- дивизимные, которые заключаются в разбиении на два кластера наиболее несхожих объектов на основе некоторого функционала качества.

Процедуры заканчивают свою работу за $N-1$ шаг, где N – количество объектов в множестве G .

С некоторой точки зрения эти процедуры, по сравнению с другими кластерными процедурами, дают более полный и тонкий анализ структуры исследуемого множества наблюдений. Их привлекательной стороной является наглядная интерпретация проведенного анализа с помощью **дендрограммы** – ациклического графа, по которому можно проследить за тем, объединение каких двух кластеров и на каком шаге произошло,

а также сделать вывод о наиболее оптимальном количестве кластеров, присутствующих в данных, определив по дендрограмме экспертное значение порога.

Агломеративные иерархические методы классификации работают по следующему алгоритму:

1) на нулевом шаге за разбиение принимается исходная совокупность n элементарных кластеров,

2) на каждом следующем шаге происходит объединение двух самых близких кластеров и соответственно пересчитывается матрица расстояний, размерность которой снижается на единицу.

Для реализации агломеративных иерархических процедур удобно использовать формулы, позволяющие находить расстояния между кластерами на $(n+1)$ шаге, используя расстояния между кластерами, рассчитанные на n -м шаге. Если обозначить через $S(t, q) = S_t \cup S_q$ группу элементов, полученную путем объединения кластеров S_t и S_q , то расстояние между кластерами S_l и $S(t, q)$ на $(n+1)$ шаге объединения будет иметь вид

$$\rho(S_l, S(t, q)) = \alpha \rho_{l,t} + \beta \rho_{l,q} + \gamma \rho_{tq} + \delta |\rho_{l,t} - \rho_{tq}|,$$

где $\rho_{lq} = \rho(S_l, S_q)$ и т.д.

Числовые коэффициенты $\alpha, \beta, \gamma, \delta$ определяются спецификой процедуры (табл. 6).

Таблица 6

Метод	α	β	γ	δ	Расстояние между объектами
Ближнего соседа	0,5	0,5	0	-0,5	$\rho_{\min}(S_l, S_t) = \min_{X \in S_l, Y \in S_t} d(X, Y).$
Дальнего соседа	0,5	0,5	0	0,5	$\rho_{\max}(S_l, S_t) = \max_{X \in S_l, Y \in S_t} d(X, Y).$
Средней связи	$\frac{n_t}{n_t + n_q}$	$\frac{n_q}{n_t + n_q}$	0	0	$\rho_{cp}(S_l, S_t) = \frac{1}{n_l n_t} \sum_{X \in S_l} \sum_{Y \in S_t} d(X, Y).$
Центроидный	$\frac{n_t}{n_t + n_q}$	$\frac{n_q}{n_t + n_q}$	$-\alpha\beta$	0	$\rho(S_l, S_t) = d(\bar{X}(l), \bar{X}(t)),$

Пример. С целью определения качества работы менеджеров с покупателями были зафиксированы следующие показатели: время, затраченное менеджерами на разговор с покупателями, и соответствующий средний размер покупок. Провести классификацию менеджеров по двум показателям с использованием метода «ближнего соседа», используя в качестве меры сходства обычное евклидово расстояние.

Решение. Исходные данные содержатся в таблице:

Менеджер	1	2	3	4	5
Время разговора с покупателем (мин)	2	4	8	12	13
Расходы на покупку	10	7	6	11	9

Вычислим простые Евклидовы расстояния между всеми пятью наблюдениями и построим матрицу расстояний.

Расстояние между первым и вторым менеджером найдем как $d(1,2) = \sqrt{(2-4)^2 + (10-7)^2} = 3,61$. Между первым и третьим менеджером: $d(1,3) = \sqrt{(2-8)^2 + (10-6)^2} = 7,21$.

Матрица расстояний будет иметь вид

$$\mathbf{D}_1 = \begin{pmatrix} 0 & 3.61 & 7.21 & 10.05 & 11.05 \\ 3.61 & 0 & 4.12 & 8.94 & 9.22 \\ 7.21 & 4.12 & 0 & 6.4 & 5.83 \\ 10.05 & 8.94 & 6.4 & 0 & 2.24 \\ 11.05 & 9.22 & 5.83 & 2.24 & 0 \end{pmatrix}.$$

Из матрицы расстояний видно, что наблюдения 4 и 5 наиболее близки $d(4,5) = 2.24$, и поэтому объединим их в один кластер. После объединения объектов получаем 4

кластера: $S_1, S_2, S_3, S_{(4,5)}$.

Расстояние между кластерами будем находить по принципу «ближнего соседа», воспользовавшись формулой пересчета. В нашем случае расстояние между кластером S_1 и кластером $S_{(4,5)}$ равно:

$$\begin{aligned} \rho_{1,(4,5)} &= \rho(S_1, S_{(4,5)}) = \frac{1}{2} \rho_{1,4} + \frac{1}{2} \rho_{1,5} - \frac{1}{2} |\rho_{1,4} - \rho_{1,5}| = \\ &= \frac{1}{2} (10.05 + 11.05) - \frac{1}{2} |10.05 - 11.05| = 10.05 \end{aligned}$$

Таким образом, расстояние $\rho_{1,(4,5)}$ равно расстоянию от объекта 1 до ближайшего к нему объекта 4, входящего в кластер $S_{(4,5)}$. Проведя аналогичные расчеты, получим новую матрицу расстояний:

$$\mathbf{D}_2 = \begin{pmatrix} 0 & 3.61 & 7.21 & 10.05 \\ 3.61 & 0 & 4.12 & 8.94 \\ 7.21 & 4.12 & 0 & 5.83 \\ 10.05 & 8.94 & 5.83 & 0 \end{pmatrix}.$$

Из матрицы видно, что наименьшее расстояние между собой имеют объекты 1 и 2 : $\rho_{1,2} = 3.61$. После объединения этих объектов получим три кластера $S_{(1,2)}, S_3, S_{(4,5)}$.

Вновь строим матрицу расстояний. Для этого воспользуемся матрицей $\mathbf{D}_2$.

Например, расстояние между кластерами $S_{(4,5)}$ и $S_{(1,2)}$ равно:

$$\begin{aligned} \rho_{(4,5),(1,2)} &= \frac{1}{2} \rho_{(4,5),1} + \frac{1}{2} \rho_{(4,5),2} - \frac{1}{2} |\rho_{(4,5),1} - \rho_{(4,5),2}| = \\ &= \frac{1}{2} (10.05 + 8.94) - \frac{1}{2} |10.05 - 8.94| = 8.94. \end{aligned}$$

Это расстояние равно расстоянию от кластера $S_{(4,5)}$ до ближайшего объекта 2, входящего в кластер $S_{(1,2)}$.

Проведя аналогичные расчеты, получим матрицу расстояний:

$$\mathbf{D}_3 = \begin{pmatrix} 0 & 4.12 & 8.94 \\ 4.12 & 0 & 5.83 \\ 8.94 & 5.83 & 0 \end{pmatrix}.$$

Объединим кластер $S_{(1,2)}$ с объектом 3, расстояние между которыми минимально:

$\rho_{(1,2),3} = 4.12$. В результате получим два кластера $S_{(1,2,3)}$ и $S_{(4,5)}$. Матрица расстояний будет иметь вид

$$\mathbf{D}_4 = \begin{pmatrix} 0 & 5.83 \\ 5.83 & 0 \end{pmatrix}.$$

Из этой матрицы следует, что на расстоянии 5,83 все пять наблюдений объединяются в один кластер. Результат кластерного анализа представим графически в виде дендрограммы (см. рис. 36).




Рис. 1. Дендрограмма

На основании графического представления результатов кластерного анализа можно сделать вывод, что наилучшим является разбиение пяти менеджеров на два кластера $S_{(1,2,3)}$ и $S_{(4,5)}$. В первый кластер попали менеджеры, которые мало тратили время на разговор с покупателями, т.е. не уделяли должного времени покупателю. Во второй кластер попали менеджеры, уделяющие много времени покупателям, и соответственно средний размер покупок у них был выше.